

实验题目	实验五			实验日期	2022.5.30
班级	1903104	学号	1190300321	姓名	郑晟赫

CS32262 模式识别与深度学习实验

实验报告

一、实验目的（介绍实验目的）

1. 生成式对抗网络实现
2. 隐空间语义方向搜索

二、实验环境（介绍实验使用的硬件设备、软件系统、开发工具等）

1. 硬件设备：CPU: i7-9750H; GPU: NVIDIA GeForce GTX 1650; 16G RAM; 512GHD Disk
2. 软件系统：Windows 10; Python 3.7.10; PyTorch 1.9.0
3. 开发工具：PyCharm

三、实验内容（介绍实验过程、设计方案、实现方法、实验结果等）

1. 生成式对抗网络实现

1.1 任务

在提供的文件中存在一个 M 型点集分布，需要使用不同的生成式对抗网络对于随机给定的噪声分布，生成能拟合给定分布的点集。

1.2 网络介绍

本部分涉及三种网络，分别是 GAN、WGAN、WGAN-GP。以下做简要介绍

GAN 包含两个模型，分别是生成模型和判别模型，生成模型的任务是生成看起来自然真实的、和原始数据相似的实例。判别模型的任务是判断给定的实例看起来是自然真实的还是人为伪造的。在训练过程中，生成网络的目的是尽量生成真实的图片来欺骗判别网络 D，而判别网络的目标在于尽量分出真实的图片和生成网络生成的图片。因此可以得到如下目标函数：

$$\min_G \max_D V(D, G) = E_{x \sim P_{data}(x)} \log(D(x)) + E_{z \sim P_z(z)} \log(1 - D(G(z)))$$

在优化过程中两个网络交替优化，目的都是使得对方的错误最大化，最终，生成器能够拟合给定的数据的分布，使得生成的样本更加真实。

WGAN 是对 GAN 的一个优化，主要解决了以下四个问题：1、彻底解决 GAN 训练不稳定的问题，不再需要小心平衡生成器和判别器的训练程度。2、基本解决了 collapse mode 的问题，确保了生成样本的多样性。3、训练过程中终于有一个像交叉熵、准确率这样的数值来指示训练的进程，这个数值越小代表 GAN 训练得越好，代表生成器产生的图像质量越高（如题图所示）。4、以上一切好处不需要精心设计的网络架构，最简单的多层全连接网络就可以做到。数学证明过程略去，其对于 GAN 的改进主要在于以下四点：1、判别器最后一层去掉 sigmoid。2、生成器和判别器的 loss 不取 log。3、每次更新判别器的参数之后把它们的绝对值截断到不超过一个固定常数 c。4、不要用基于动量的优化算法（包括 momentum 和 Adam），推荐 RMSProp 或 SGD。

虽然 WGAN 在稳定性训练方面有了比较好的进步，但是有的时候只能生成比较差的样本，而且有的时候比较难以收敛。因此 WGAN-GP 方法被提出，其针对 WGAN 的改进就是在目标函数中加入了一个梯度的惩罚项。则目标函数变为如下形式：

实验题目	实验五			实验日期	2022.5.30
班级	1903104	学号	1190300321	姓名	郑晟赫

$$L = E_{X \sim P_g}[D(x)] - E_{X \sim P_r}[D(x)] + \lambda E_{\hat{x} \sim P_{\hat{x}}}[(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2]$$

加入梯度约束后，保证了 w 不超过某个常数，因此从保证 Lipschitz 连续的条件上，GP 的作用跟 weight clip 是一样的。

1.3 实验结果对比

在本实验中 GAN 的性能已经可以满足在较短时间内拟合给定分布。当训练 30 个 epoch 的时候就已经基本能拟合出给定分布的形状（见图 1），最终 100 个 epoch 时候已经基本能拟合上给定分布（见图 2）。




图 1 GAN epoch=30




图 2 GAN epoch=100

使用 WGAN 拟合给定分布的时候，拟合的相对于 GAN 来说比较慢，但是从最终的拟合结果来看比 WGAN 略好。具体结果可见图 3 和图 4。




图 3 WGAN epoch=40




图 4 WGAN epoch=100

使用 WGAN-GP 的效果与 GAN 差不多，具体结果可见图 5 和图 6。




图 5 WGAN-GP epoch=40




图 6 WGAN-GP epoch=90

实验题目	实验五			实验日期	2022.5.30
班级	1903104	学号	1190300321	姓名	郑晟赫

总的来说，在拟合这个数据集的任务中三种网络的表现事实上是差不多的，其中 WGAN 和 WGAN-GP 可能由于限制了参数范围，因此拟合的速度相较于 GAN 来说稍慢，但是这两种网络最终的结果都能比 GAN 略好。

1.4 优化器对比

优化器对最终拟合结果的影响方面以 GAN 网络为例，展示 SGD、Adam 与 RMSProp 三种优化器对最终拟合效果的影响。首先考虑 SGD 优化器。使用 SGD 优化器时收敛的速度是在三种优化器中相对较慢的，训练中在第 135 个 epoch 才出现了大致的拟合图案（见图 7），且在训练过程中，其余两种网络只需要训练 5 次判别器后训练一次生成器即可收敛，但是使用 SGD 的时候需要训练 20~30 次判别器后训练一次生成器才能达到比较好的收敛情况（见图 8）。




图 7 GAN SGD epoch=135




图 8 GAN SGD epoch=160

Adam 优化器训练的速度相较于 SGD 来说有比较大的提升，在每个 epoch 中只需要训练 5 次判别器后训练一次生成器即可收敛，但是具体收敛最终情况不如 SGD 的收敛情况（见图 9）。




图 9 GAN ADAM epoch=200

相对来说 RMSprop 优化器是这三种优化器中表现最好的，无论是从收敛的速度还是最终收敛时候表现出的拟合形状来看。具体训练情况见图 10, 11。

实验题目	实验五			实验日期	2022.5.30
班级	1903104	学号	1190300321	姓名	郑晟赫




图 10 GAN RMSprop epoch=30




图 11 GAN RMSprop epoch=80

2. 隐空间语义方向搜索

2.1 算法简要介绍

本次实验采用 SeFa 算法进行隐空间语义方向搜索。为了改变输出图像中的特定属性(例如头发颜色、面部表情、姿势、性别等), 我们需要知道移动潜在向量 z 的特定方向。SeFa 是一种封闭形式的无监督方法, 可以无需数据采样和模型训练并找出这些方向向量来改变输出图像中的不同属性。主要的方式是通过 GAN 中的第一个全连接层之后将隐空间方向搜索问题转化为一个优化问题, 使用求出的对应前 K 个特征值的特征向量作为隐空间的语义方向。

2.2 实验结果分析

实验过程中计算了 5 个语义方向, 并做出转换前后的图像。以下逐一分析。

首先是第一个方向, 生成图像可见图 12, 观察图像的变化可以得出这个方向的语义含义是人脸的头发长度, 且由于头发长度的修改, 部分图片中出现了背景的变化。



图 12 第一个方向转换图

第二个方向生成图像可见图 13, 这个方向的语义含义是将人脸转换为男性。可以观察到, 除了第 2 行的原始图像就是男性, 其余行均从女性人脸变换成了男性人脸。观察第 2 行的变化过程可以发现脸上的胡子等男性特征变得更加明显。



图 13 第二个方向转换图

实验题目	实验五			实验日期	2022.5.30
班级	1903104	学号	1190300321	姓名	郑晟赫

第三个方向生成图像见图 14，这个方向的语义含义是转换人脸的朝向。




图 14 第三个方向转换图

第四个方向生成图像见图 15，这个方向的语义含义是修复比较模糊或略有变形的人脸。



图 15 第四个方向转换图

第五个方向生成图像见图 16，这个方向的语义含义是年龄，将年轻的人脸改变为年龄稍大的人脸。



图 16 第五个方向转换图

四、实验结论（总结实验发现及结论）

经过本次实验对于生成对抗网络的几种基本形式有了一定的认识，同时对于目前比较前沿的生成对抗网络的应用也有了一定的了解。