句法分析

杨沐昀
教育部-微软语言语音重点实验室
MOE-MS Joint Key Lab of NLP and Speech (HIT)

序

- “微观”语言学分支对应了不同的NLP基础技术
  - 词法学——自动分词、词性标注
  - 句法学——句法分析
- 句法(Syntax): 研究语言的句子结构
  - 自希腊语，字意是排列
  - Studies how words are combined to form sentences and the rules that govern the formation of sentences.
  - 语言学两个基本关系：聚合关系vs组合关系
- 思考题：NLP研究为什么要关注句法分析？

内容提要

- 句法分析概述
- 句法分析算法的主要处理策略
  - 移进-规约
  - 线图分析（Chart）

句法分析概述

- 基本任务：确定句子的句法结构或句子中词汇之间的依存关系。
- 定义：判断单词序列（一般为句子）判读其构成是否合乎给定的语法(recognition)，如果是，则给出其（树）结构(parsing)

子问题1： 语言体系的形式化描述

子问题2： 语言结构的分析算法

句法结构分析概述

- 给定英语单词：the,can,hold,water的词性信息、及句法规则：

the : art(冠词)
can : n, aux, v(n, v表示名词和动词,aux表示助动词)
hold : v
water : n, v

s -> NP VP
NP -> art n
VP -> aux VP
VP -> v NP

- 那么句子The can can hold the water 的分析树如下所示：

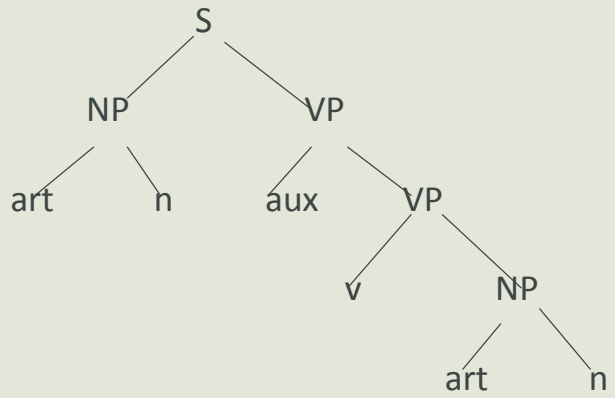

句法分析概述：语言的描述

- 一般的，描述一种语言可以有三种途径：
  1. 穷举法：把语言中的所有句子都枚举出来。显然，这种方法只适合句子数目有限的语言
  2. 语法/文法描述：语言中的每个句子用严格定义的规则来构造，利用规则生成语言中合法的句子
  3. 自动机法：通过对输入句子进行合法性检验，区别哪些是语言中的句子，哪些不是语言中的句子
- 语法/文法用来精确的描述语言和其结构，自动机则是用来机械地刻画对输入字符串的识别过程

句法分析概述：形式语法的定义

- 形式语法： 四元组 $G = \{N, \Sigma, P, S\}$
  - N是非终结符(non-terminal symbol)的有限集合(有时也称变量集或句法种类集)
  - Σ是终结符号(terminal symbol)的有限集合，$N \cap \Sigma = \emptyset$
    - （ Σ也经常用T标示）
    - V = $N \cup \Sigma$称为总词汇表
  - P是一组重写规则的有限集合：$P = \{\alpha \to \beta\}$，其中α, β是由V中元素构成的串，但是α中至少应含一个非终结符
  - $S \in N$称为句子符或初始符

句法分析概述：形式语法种类

- 正则文法：如果文法G的规则集P中所有规则均满足如下形式：$A \to Bx$或$A \to x$,其中$A, B \in N, x \in \Sigma$,则称该文法G为正则文法，或称3型文法
- 上下文无关文法：如果文法G的规则集P中所有规则均满足如下形式： $A \to \alpha$,其中$A \in N, \alpha \in (N \cup \Sigma)^*$，则称该文法为上下文无关文法(context-free grammer, CFG)，或称2型文法
- 上下文相关文法：如果文法G的规则集P中所有规则均满足如下形式： $\alpha A \beta \to \alpha \gamma \beta$,其中$A \in N, \alpha, \beta, \gamma \in (N \cup \Sigma)^*$,且$\gamma$至少包含一个字符，则称G为上下文相关文法(context-sensitive grammer,CSG)，或称1型文法
- 无约束文法：如果文法G的规则集P中所有规则均满足如下形式：$\alpha \to \beta$ ，其中$\alpha \in (N \cup \Sigma)^+$，$\beta \in (N \cup \Sigma)^*$ ，则称G无约束文法，也称0型文法

句法分析概述：形式文法的乔姆斯基层级体系

分级	名称	产生式规则的形式限制
0	PSG	$\alpha \rightarrow \beta$ with $\alpha \in (V_T \cup V_N)^+$ and $\beta \in (V_T \cup V_N)^*$
1	CSG	$\alpha_1 A \alpha_2 \rightarrow \alpha_1 \beta \alpha_2$ with $A \in V_N$ and $\alpha_1, \alpha_2 \in (V_T \cup V_N)^*$ and $\beta \in (V_T \cup V_N)^+$
2	CFG	$A \rightarrow \beta$ with $A \in V_N$ and $\beta \in (V_T \cup V_N)^*$
3	RG	$A \rightarrow \beta B$ or $A \rightarrow \beta$ with $A, B \in V_N$ and $\beta \in V^*_T$

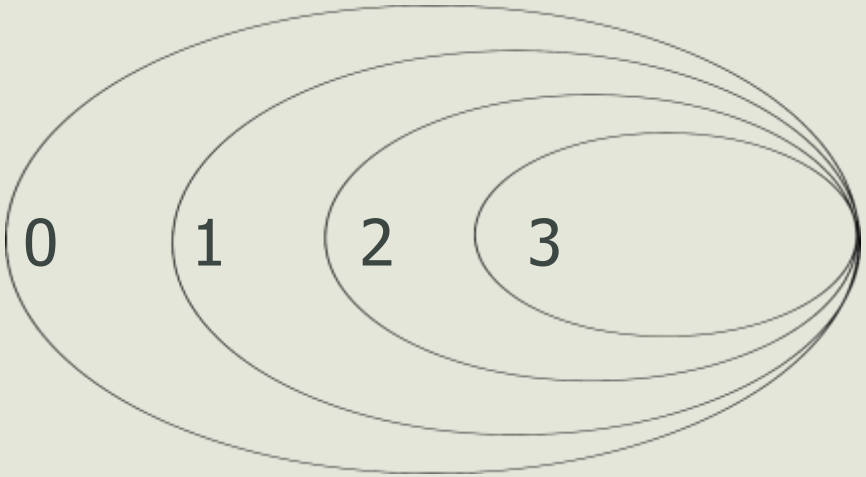

G_0：无限制重写文法 PSG

G_1：上下文相关文法 CSG

G_2：上下文无关文法 CFG

G_3：正则文法 RG

句法分析概述：文法、自动机和语言

	文法	自动机	语言	复杂度
0型	无约束文法	图灵机	递归可枚举语言	半可判定
1型	上下文相关文法	线性界限自动机	上下文相关语言	NP完全
2型	上下文无关文法	下推自动机	上下文无关语言	多项式
3型	正则文法	有限自动机	正则语言	线性

句法分析概述：文法与自然语言

- 上下文无关文法使用最普遍
  - 正则语法描述能力太弱、上下文相关语法计算复杂度太高
- 计算复杂度：上下文无关文法的复杂度是多项式的，其复杂度可以忍受
- 描述能力：上下文无关文法不足以描述自然语言，自然语言中上下文相关的情况非常常见；
- 为弥补上下文无关文法描述能力的不足，需要加上一些其他手段扩充其描述能力
- 思考题：这种现实的选择是否意味着放弃了科学？会不会造成计算语言学与NLP分道扬镳？

句法分析概述：用CFG描述自然语言

1. S → np vp
2. np → vp u np
3. vp → pp vp
4. vp → vp u
5. pp → p np
6. np → n
7. vp → v
8. n → 老师 | 学生 …
9. v → 迟到 | 逗乐 …
10. p → 被 …
11. u → 的| 了 …

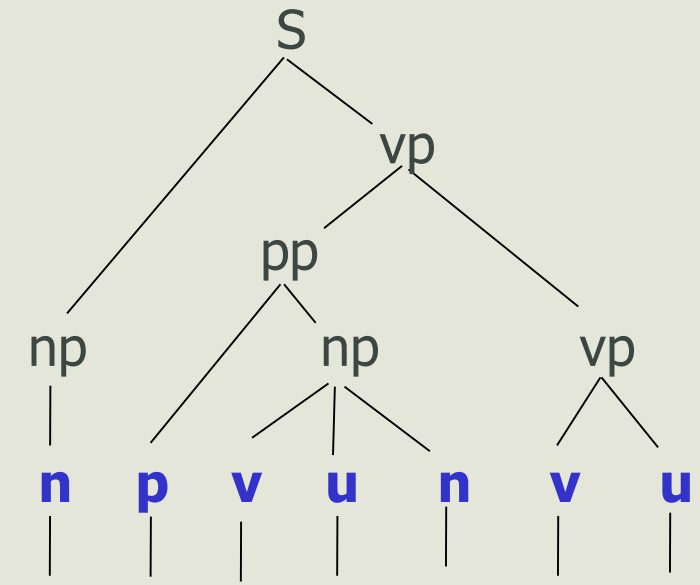

内容提要

- 句法分析概述
- 句法分析算法的主要处理策略

句法分析算法的主要处理策略

- 自顶向下、自底向上是两种控制策略
- 深度优先和广度优先是搜索策略，都适用两种控制策略
  - 探索多种可能性时选择的排队策略(栈或队列)
- 自左至右和自右至左(甚至”中间开花”)是常用的两种扫描策略
- 当文法没有二义性时,甚至假设句子理解没有二义性时,可以采用确定性算法(无回溯);对自然语言一般不行

自底向上和自顶向下

自底向上（bottom-up）

（从构成语法分析树叶子结点的终结符号串开始，从底部开始构造语法分析树）

基于归约的方法

从待分析字符串开始，用待分析字符串去匹配CFG规则箭头的右部字符，匹配成功后替换为左部字符，直到S

自顶向下（top-down）

（从文法的开始符号出发，从顶部开始构造语法分析树）

基于预测的方法

从CFG规则中的S规则开始，将CFG规则箭头左部的符号展开，直到形成以终结符开始的序列，用该序列去匹配待分析字符串，直到完全匹配上

自顶向下和自底向上

Bottom - Up

John, hit, the, cat

pron, hit, the, cat

pron, v, the, cat

pron, v, det, cat

pron, v, det, n

np, v, det, n

np, v, np

np, vp

s

常用策略

Top - Down

s

s -> np, vp

s -> pron, vp

s -> John, vp

s -> John, v, np

s -> John, hit, np

s -> John, hit, det,n

s -> John, hit, the,n

s -> John, hit, the,cat

移进 - 归约算法

- **自底向上**的语法分析过程：为一个输入串构造语法分析树的过程，它从叶子结点逐渐向上到达根节点。
- **归约**：我们可以将自底向上语法分析的过程看成将一个串 w “归约”为文法开始符号的过程。
- **移进-归约**是自底向上语法分析的一种形式
  - 使用一个栈来保存文法符号，并用一个输入缓冲区来存放将要进行语法分析的其余符号
  - 使用最基础的一种数据结构就可实现

移进 - 归约算法

- 我们使用 # 来标记栈的底部以及输入的右端。如下所示，开始的时候栈是空的，并且输入串w存放在输入缓冲区中。

栈	输入
#	w#

- 在对输入串的一次从左到右的扫描过程中，语法分析器将零个或多个输入符号移到栈的顶端，直到它可以对栈顶的一个文法符号串进行归约为止。
- 重复这个循环直到遇到语法错误，或栈中包含了开始符号且输入缓冲区为空。

栈	输入
#w	#

进入这样的状态时，分析成功

移进 - 归约算法

- 基本数据结构：**堆栈**
- 虽然主要的分析操作是移进和归约，但实际上可能会采取四种操作
  - **移进(Shift)**：从句子左端将一个终结符移到栈顶
  - **归约(Reduce)**：根据规则，将栈顶的若干个符号替换成一个符号
  - **接受(accept)**：句子中所有词语都已移进到栈中，且栈中只剩下一个符号S，宣布分析成功，结束
  - **报错(error)**：句子中所有词语都已移进栈中，栈中并非只有一个符号S，也无法进行任何归约操作（即发现一个语法错误），分析失败，结束
- 使用栈的原因：分析过程中，需要合并的前序点总是出现在栈的顶端，绝不会出现在栈的中央

移进-归约冲突举例

- 两种冲突
  - 移进 - 归约冲突：既可以移进，又可以归约
  - 归约 - 归约冲突：可以使用不同的规则归约

移进归约冲突：

- 给定语法：
- $stmt \rightarrow \textbf{if}\ expr\ \textbf{then}\ stmt$

  $\quad | \ \textbf{if}\ expr\ \textbf{then}\ stmt\ \textbf{else}\ stmt$

  $\quad | \ \textbf{other}$
- 如果此时分析器处于

栈	输入
… **if** *expr* **then** *stmt*	**else** . . . #

- 此时无法确定将栈中的串归约还是将输入中的**else**移进

归约-归约冲突举例

- 给定语法：
- $stmt \rightarrow \mathbf{id}$ $expr \rightarrow \mathbf{id}$
- 若此时分析器状态为

栈	输入
… **id**	**Y** . . . #

- 显然栈顶的**id**需要被规约，但是使用上述哪一条产生式是无法即刻解决的

移进-归约方法分析

- 冲突解决方法：回溯
  - 回溯策略：对于互相冲突的各项操作，给出一个选择顺序
    - 移进 - 归约冲突：优先进行归约，如果失败再尝试移进
    - 归约 - 归约冲突：规则事先排序，优先执行排在前面的规则
  - 断点信息
    - 除了在堆栈中除了保存非终结符外，还需要保存断点信息，使得回溯到该断点时，能够恢复堆栈的原貌，并知道还可以有哪些可选的操作

实例:移进-归约分析过程

- 句法规则
  - (1) S → NP VP
  - (2) NP → N
  - (3) NP → CS de
  - (4) CS → NP V'
  - (5) VP → V NP
  - (6) V' → V V
- 输入句子

  我 是 上级 派 来 的

  N V N V V de

实例:移进-归约分析过程

栈	输入	操作
#	N V N V V de	sh

文法规则：

(1) S → NP VP

(2) NP → N

(3) NP → CS de

(4) CS → NP V'

(5) VP → V NP

(6) V' → V V

我 是 上级 派 来 的

N V N V V de

实例:移进-归约分析过程

栈	输入	操作
#	N V N V V de	sh
# N	V N V V de	r(2) [or sh?]
# NP	V N V V de	sh
# NP V	N V V de	sh
# NP V N	V V de	r(2) [or sh?]
# NP V NP	V V de	r(5) [or sh?]
# NP VP	V V de	r(1) [or sh?]
# S	V V de	sh
# S V	V de	sh
# S V V	de	sh [not r(6)]

文法规则：

(1) S → NP VP

(2) NP → N

(3) NP → CS de

(4) CS → NP V'

(5) VP → V NP

(6) V' → V V

严格地说：此时已经可以判定失败！

我 是 上级 派 来 的

N V N V V de

实例:移进-归约分析过程

栈	输入	操作
#	N V N V V de	sh
# N	V N V V de	r(2) [or sh?]
# NP	V N V V de	sh
# NP V	N V V de	sh
# NP V N	V V de	r(2) [or sh?]
# NP V NP V	V de	sh [not r(5)]

文法规则：

(1) S → NP VP

(2) NP → N

(3) NP → CS de

(4) CS → NP V'

(5) VP → V NP

(6) V' → V V

我 是 上级 派 来 的

N V N V V de

思考题：请补齐得到正确的句法分析树的移进-归约过程(P21)，并标注每一步的其他可能的分析操作

分析结果：句法结构树

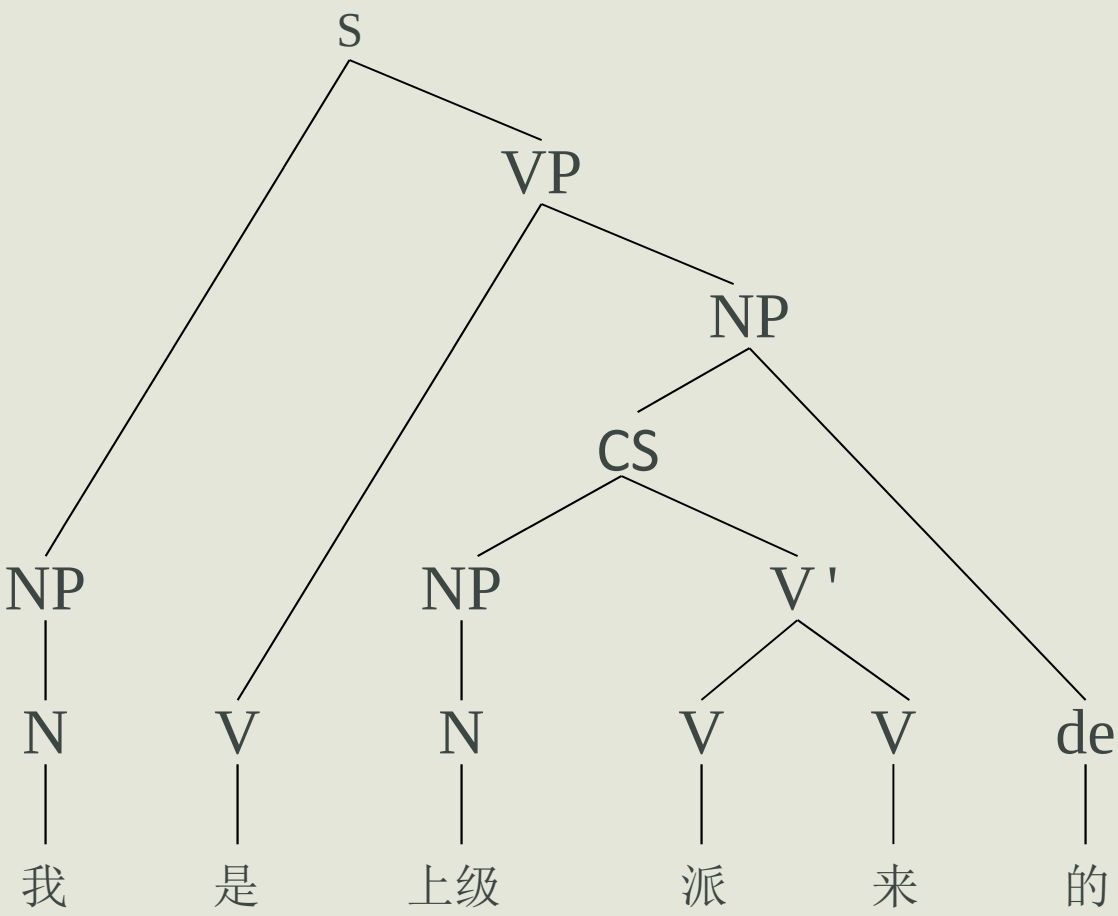

移进-归约方法分析

- 移进 - 归约算法是一种**自底向上**的分析算法
- 为了得到正确的分析结果，可以在每次分析失败时都强制性回溯，直到分析成功
  - 可回溯的点需要被记录
- 可以看到，采用回溯算法将导致大量的冗余操作，效率非常低
- 核心问题：如何提高效率
  - 第一个想法：去掉冗余

线图分析算法（Chart parsing）

- Chart：data structure that allows storing of partial analyses, so that they can be shared.
- A *Bottom-Up* parsing method
  - Construct a parse starting from the input symbols
  - Build constituents from sub-constituents
  - When all constituents on the RHS of a rule are matched, create a constituent for the LHS of the rule

RHS: right hand side; LHS: left hand side

基本概念：线图/chart

- 线图是一组节点(node)和边(edge)的集合
  - 节点：对应着输入字符串中的字符间隔
  - 边：<起点, 终点, 标记>
    - 其中标记为非终结符或终结符
- 问题：如何从输入串开始，一步步形成chart，使得存在一条边可以覆盖全部节点，并且边上标记为S？

备忘：线图分析法是基于CFG规则的分析方法

线图分析图示

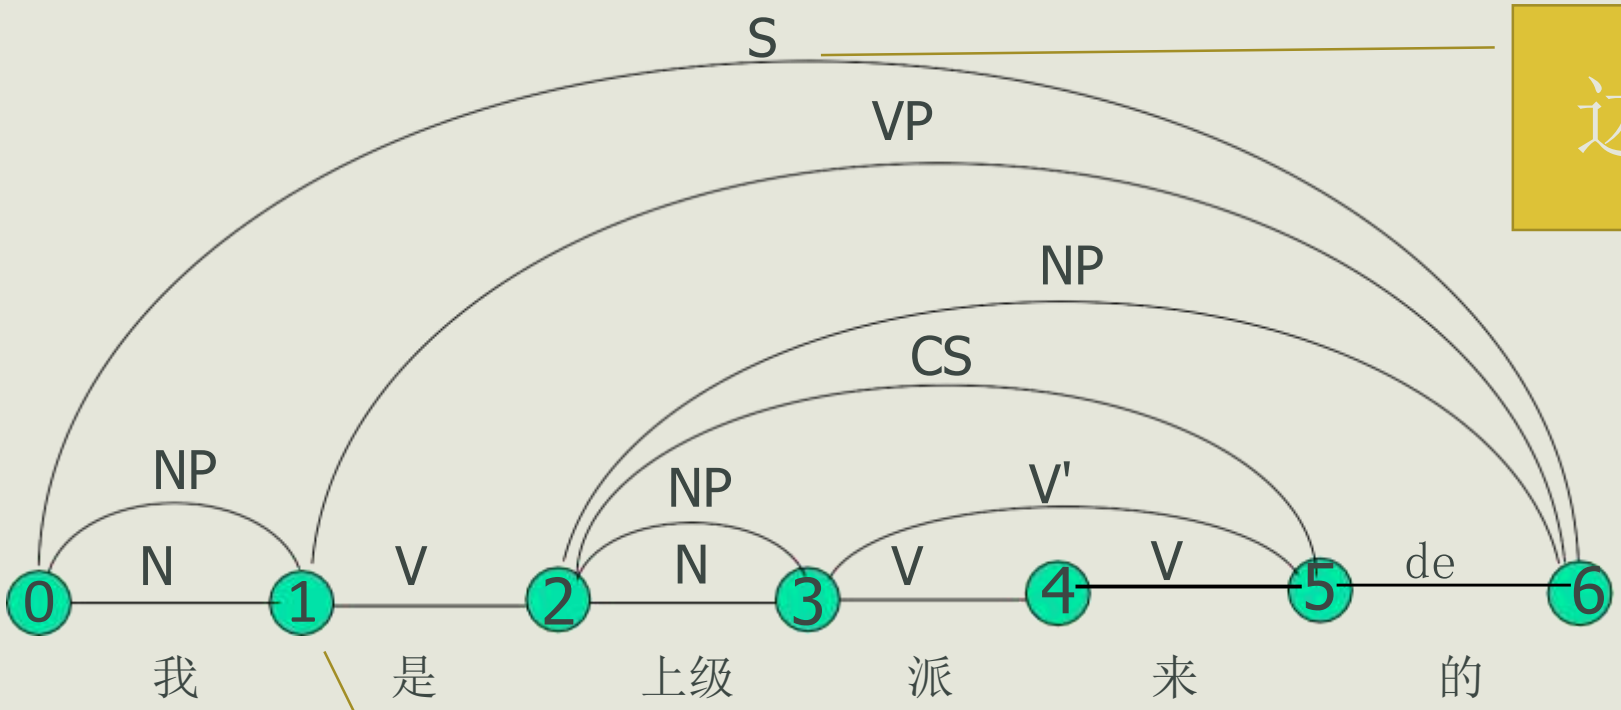

线图

Chart

点规则（Dot rule）

- 当考虑自左至右分析时，引入点规则表明分析的状态。
- 点规则由四部分组成：

（1）上下文无关文法规则

（2）圆点·（圆点左边的部分是已分析的，右边是待分析的）

（3）整数i：起点（已分析子串的起点）

（4）整数j：终点（已分析子串的终点） $i \leq j$

比如：S → NP ·VP <0,4>

对回溯点的更有效的标记

表示在寻找 S 的过程中，在词 0 到 4 之间已发现一个 NP, 期望下面有一个 VP

线图分析算法——数据结构

1) chart（线图）

{edge$_{[i]}$} i=1,2,…　edge := <P1,P2, Label>

保存分析过程中已经建立的成分和位置

2) agenda（议程表，待处理表）

存放等待加入到chart中的边（edge）

可以栈（stack）结构，或队列（queue）结构实现

3) active arc（活动弧）

如果点不在产生式的最右部，在分析中称为“活动弧”，存放分析过程中的中间状态

Chart算法的过程描述

1） 将待分析字符串w置入输入缓冲区，agenda清为空栈；

2） 循环，反复执行下面步骤，直至输入缓冲区和agenda均为空

扫描移进

a） 若agenda为空，则从输入缓冲区取一个字符，并把该字符及其起止位置(P1, P2)推入agenda栈；

b） 若agenda不为空，则从agenda中弹出栈顶的边，该边的起止位置为(P1, P2)，边上标记为L；

c） 检查规则集中的规则，对所有形如A➔L β这样的规则，在active arc集合中增加一条起止位置为P1, P2，弧上为A➔L ·β这样的点规则；

d） 把从agenda中弹出的标记为L的边，加入到chart中的P1, P2之间；

归约 → e） 检查所有active arc，如果存在起止位置为P0, P1，且弧上点规则为A➔ α ·L β 的active arc，就增加一条新的active arc，起止位置为P0, P2，弧上点规则为A➔ α L ·β

预测 → f） 如果一条active arc（起止位置为P0, P2）上点规则形如A➔ α L ·（点号在规则最右端），就将起止位置为P0, P2，边上标记为A的边压入agenda栈。

agenda中的这条边将为下面的分析指出方向：移进所有右部以A开头的规则（步骤b，c）

Chart算法分析示例

文法规则：

(1) S → NP VP

(2) NP → N

(3) NP → CS de

(4) CS → NP V'

(5) VP → V NP

(6) V' → V V

chart

0 1 2 3 4 5 6

active arc

“线图”用于存放已经确定的分析结果

“活动弧”用于存放分析的中间结果
（包括尚未确定的，和已经确定的分析结果）

agenda

“议程表”用于中转当前正在处理的边

N	V	N	V	V	de

输入缓冲区

Chart算法分析示例

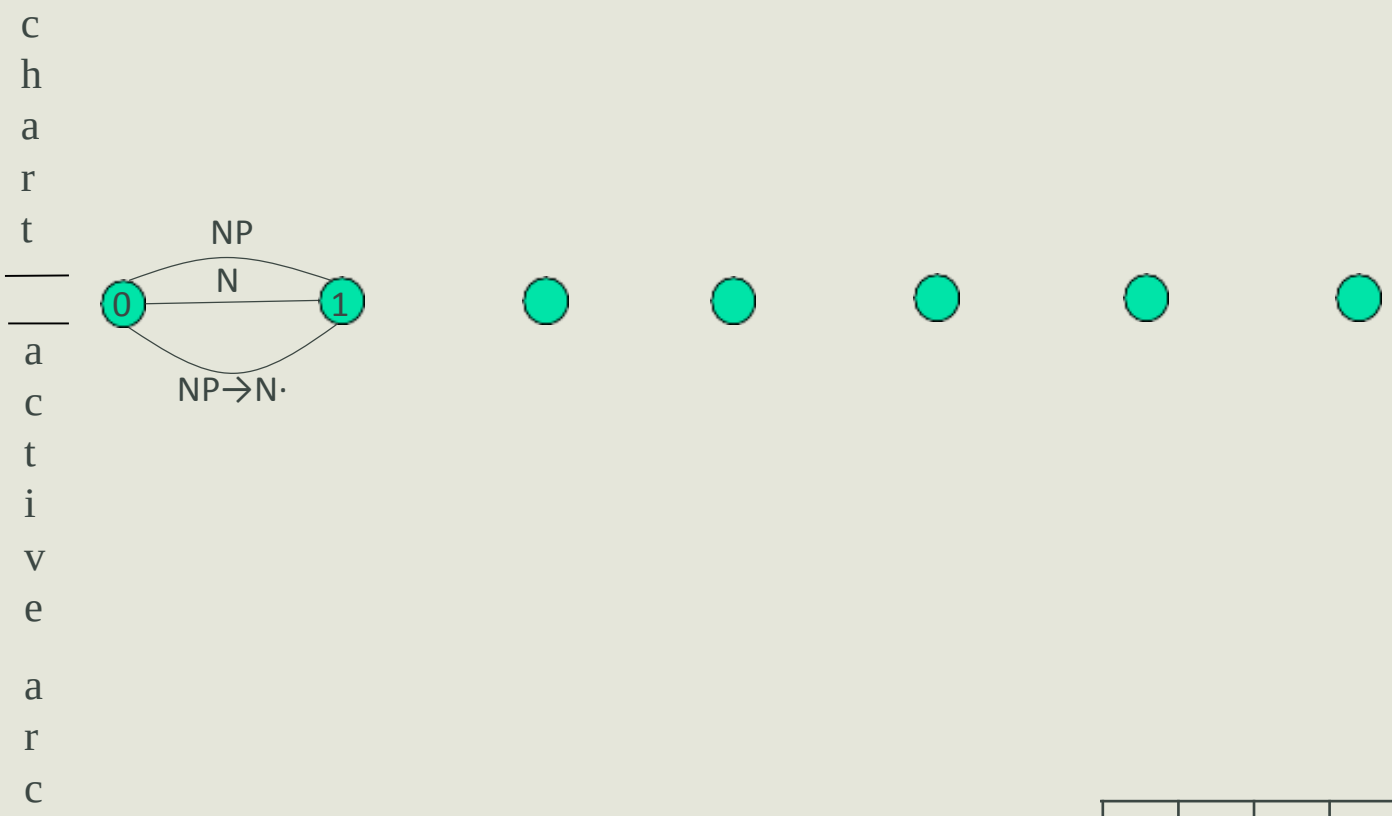

文法规则：

(1) S → NP VP

(2) NP → N

(3) NP → CS de

(4) CS → NP V'

(5) VP → V NP

(6) V' → V V

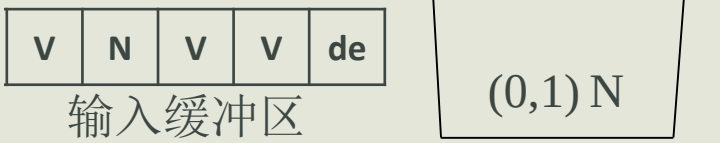

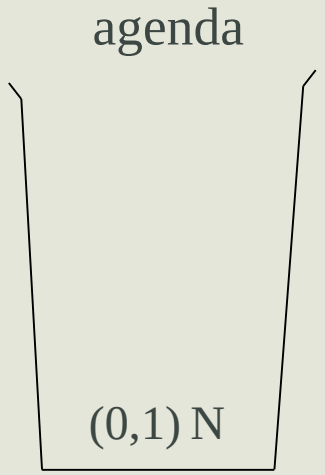

Chart算法分析示例

chart

active arc

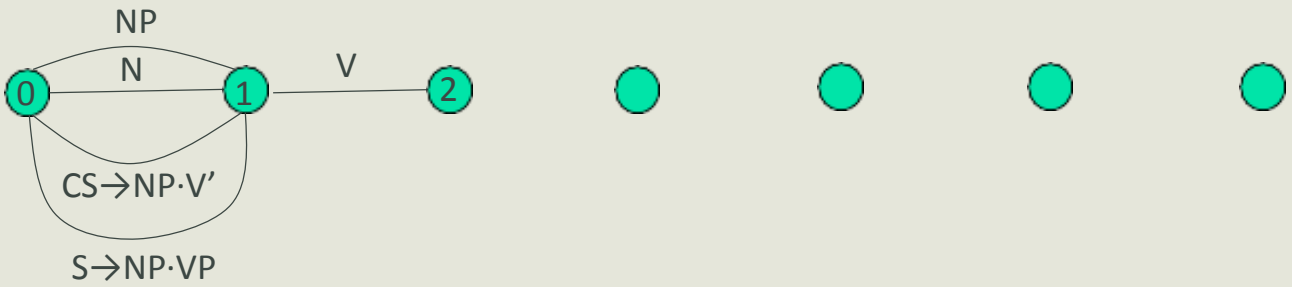

文法规则：

(1) S → NP VP

(2) NP → N

(3) NP → CS de

(4) CS → NP V'

(5) VP → V NP

(6) V' → V V

agenda

(1,2) V

N	V	V	de

输入缓冲区

Chart算法分析示例

文法规则：

(1) S → NP VP

(2) NP → N

(3) NP → CS de

(4) CS → NP V'

(5) VP → V NP

(6) V' → V V

chart

active arc

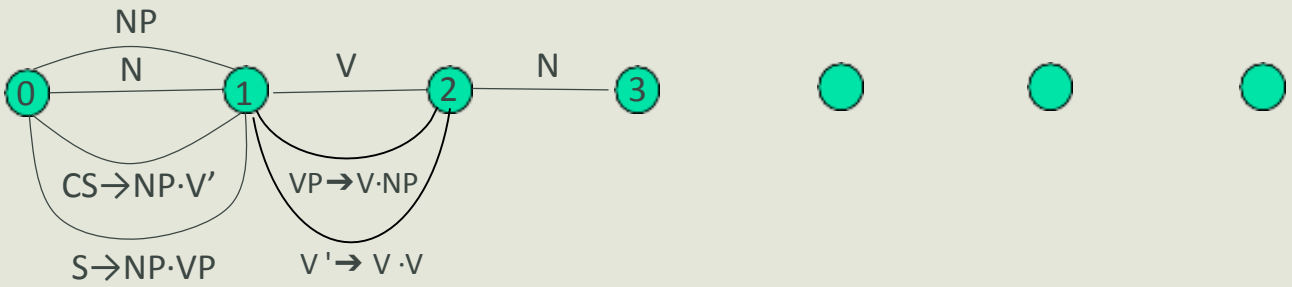

agenda

(2,3) N

V	V	de

输入缓冲区

Chart算法分析示例

chart

active arc

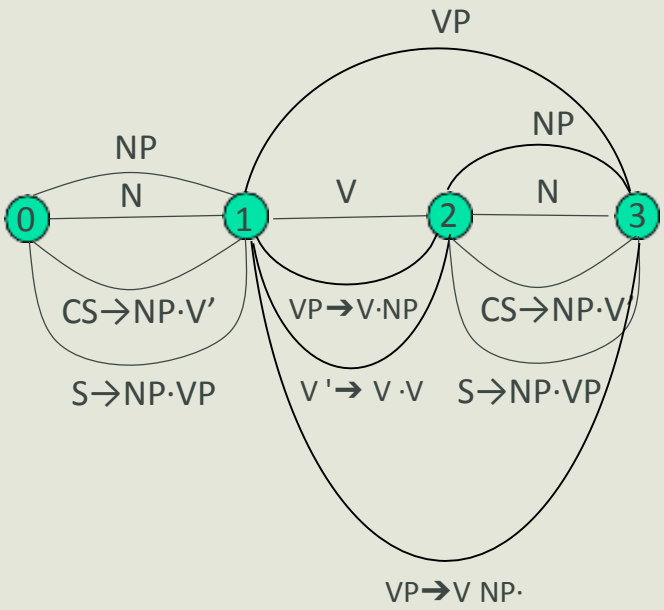

文法规则：

(1) S → NP VP

(2) NP → N

(3) NP → CS de

(4) CS → NP V'

(5) VP → V NP

(6) V' → V V

agenda

(1,3) VP

V	V	de

输入缓冲区

Chart算法分析示例

chart

active arc

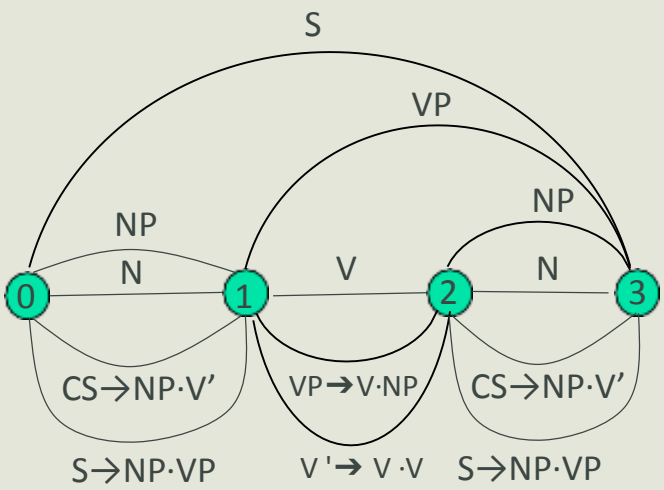

文法规则：

(1) S → NP VP

(2) NP → N

(3) NP → CS de

(4) CS → NP V'

(5) VP → V NP

(6) V' → V V

agenda

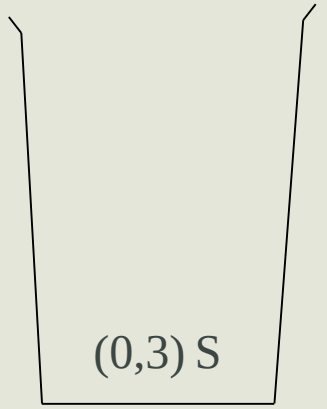

输入缓冲区

Chart算法分析示例

chart

active arc

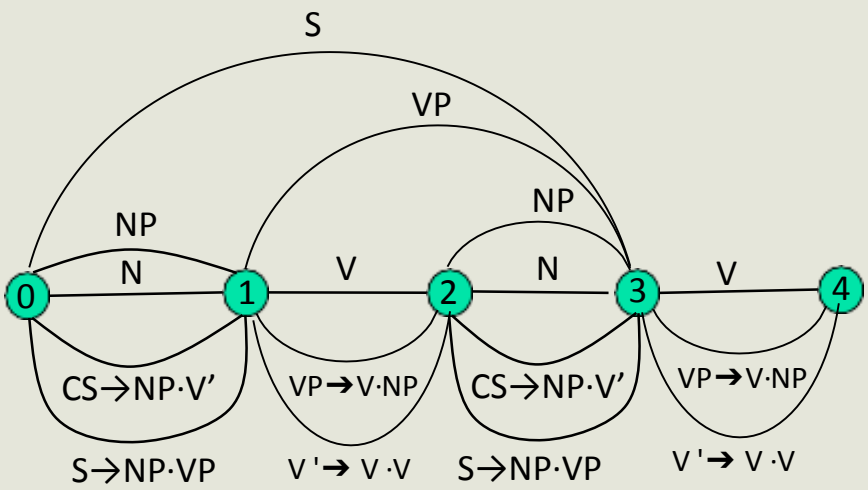

文法规则：

(1) S → NP VP

(2) NP → N

(3) NP → CS de

(4) CS → NP V'

(5) VP → V NP

(6) V' → V V

agenda

(3,4) V

V	de

输入缓冲区

Chart算法分析示例

chart

active arc

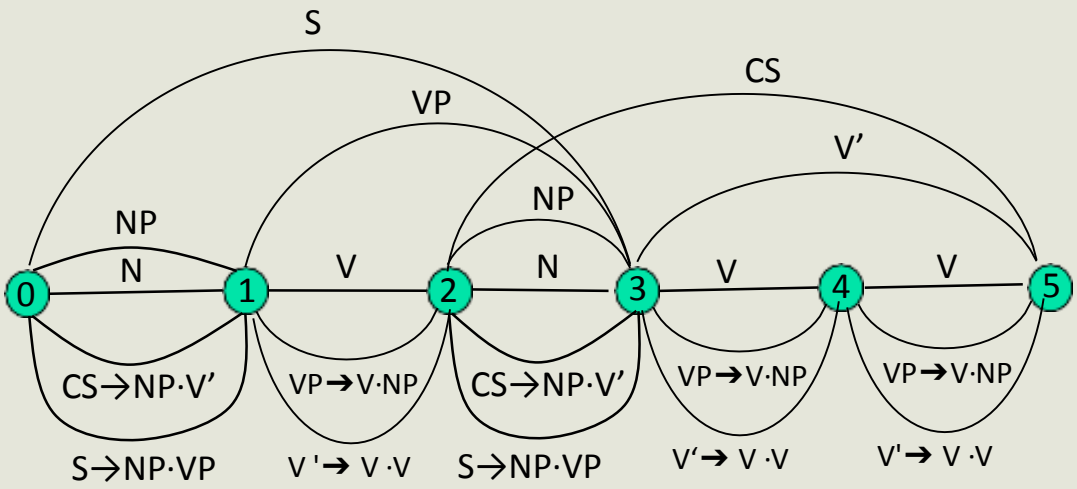

文法规则：

(1) S → NP VP

(2) NP → N

(3) NP → CS de

(4) CS → NP V'

(5) VP → V NP

(6) V' → V V

agenda

de

输入缓冲区

(4,5) CS

(2,5) S

Chart算法分析示例

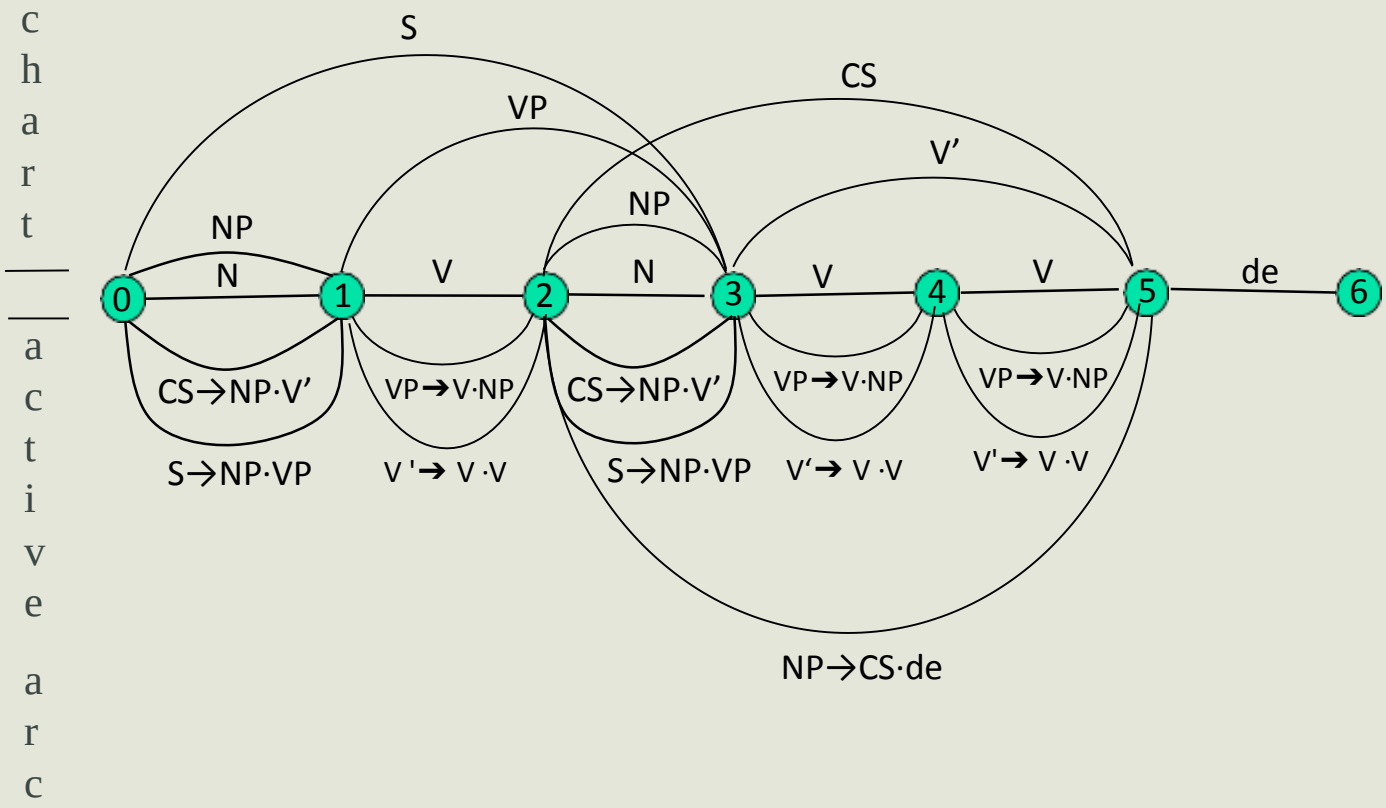

文法规则：

(1) S → NP VP

(2) NP → N

(3) NP → CS de

(4) CS → NP V'

(5) VP → V NP

(6) V' → V V

agenda

(5,6) de

输入缓冲区

Chart算法分析示例

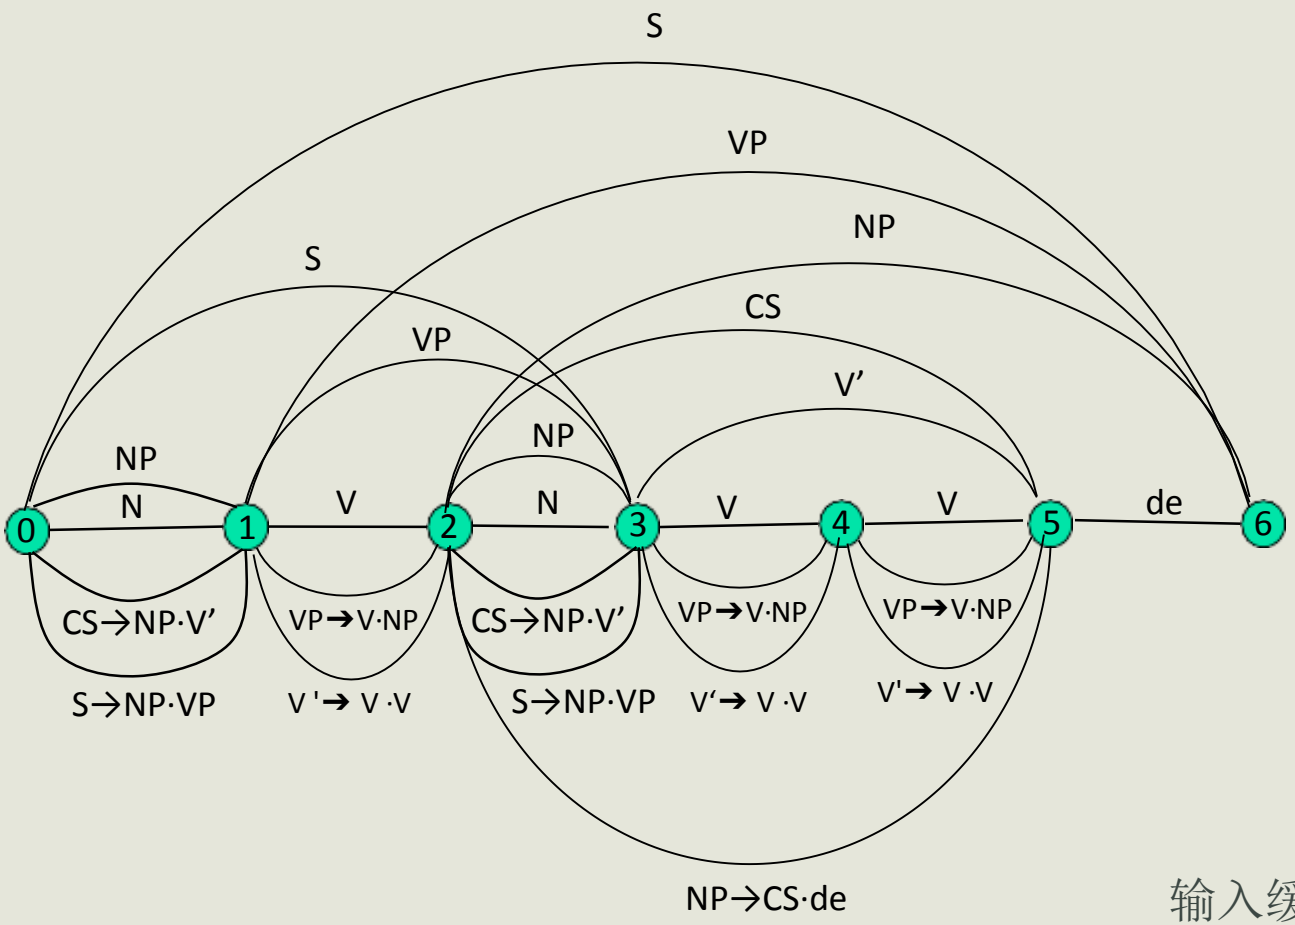

文法规则：

(1) S → NP VP

(2) NP → N

(3) NP → CS de

(4) CS → NP V'

(5) VP → V NP

(6) V' → V V

agenda

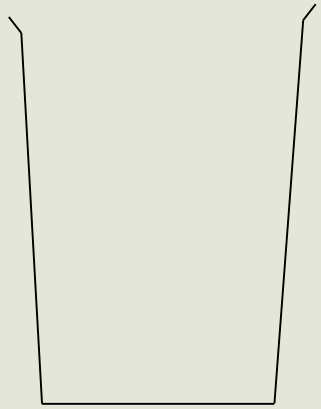

输入缓冲区

Chart算法分析示例

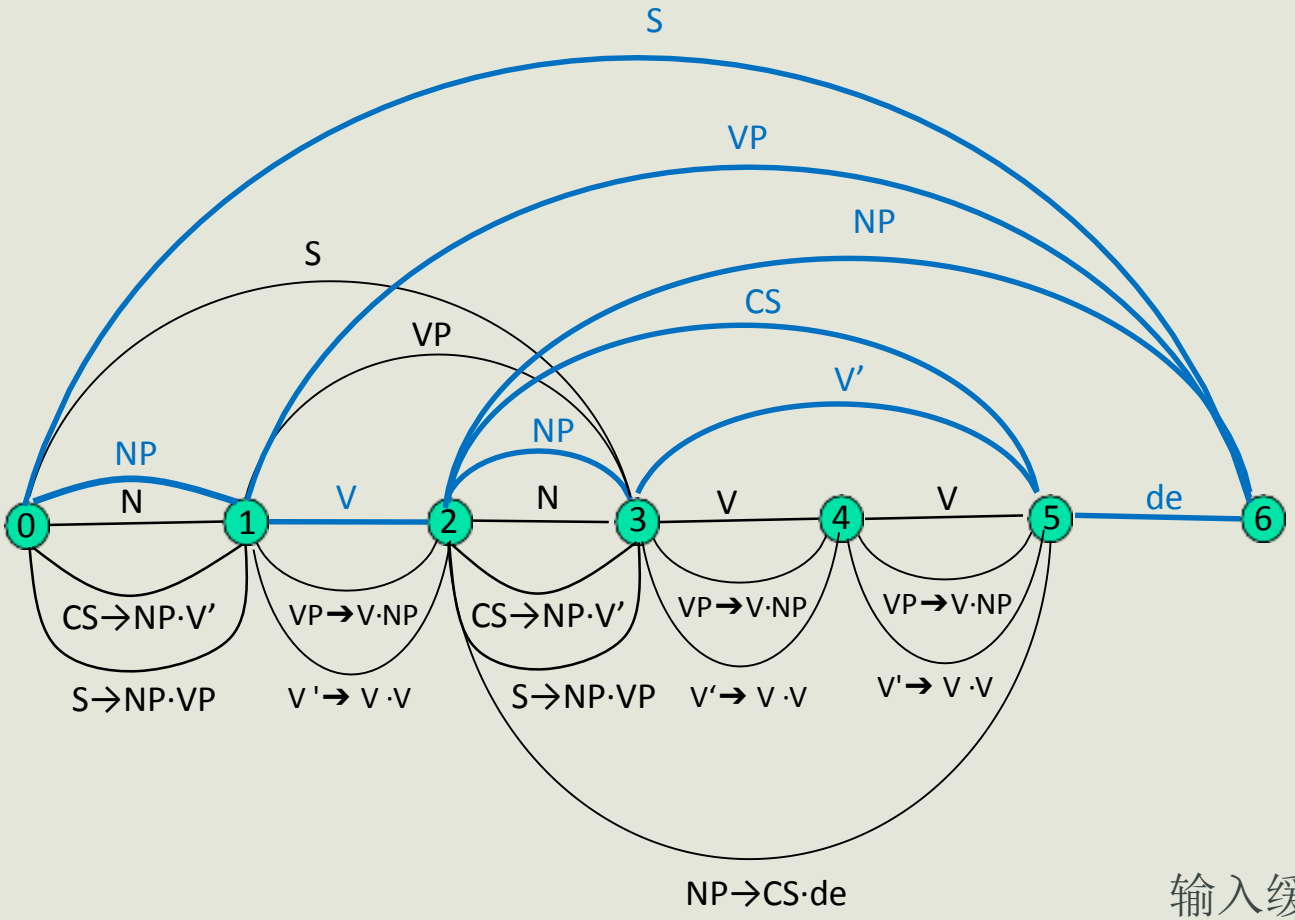

文法规则：

(1) S → NP VP

(2) NP → N

(3) NP → CS de

(4) CS → NP V'

(5) VP → V NP

(6) V' → V V

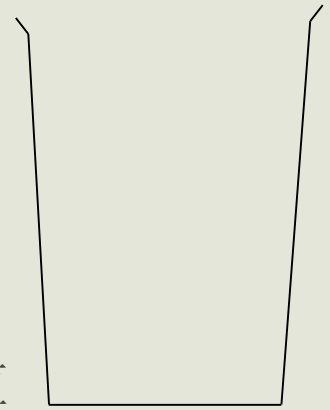

Chart算法分析

- 优点
  - 简单、容易实现
- 弱点
  - 效率不高，算法复杂度为$O(n^3)$
  - 严重依赖句法规则质量
  - 难以区分歧义结构

小结

- 句法分析：文法+算法
- 算法
  - 贪心实现+回溯
  - 全局遍历
- 下一步优化：找到合适的路径代价(启发信息)