上下文里的乾坤：组合还是聚合

语义计算初步
——词义消歧

杨沐昀

哈工大教育部-微软语言语音重点实验室

MOE-MS Joint Key Lab of NLP and Speech (HIT)

1.概述

- 词法、句法分析结果：

一只白色的小猫趴在地毯上

一/m 只/q 白色/ng 的/used 小猫/ng 趴/vg 在/p 地毯/ ng 上/f

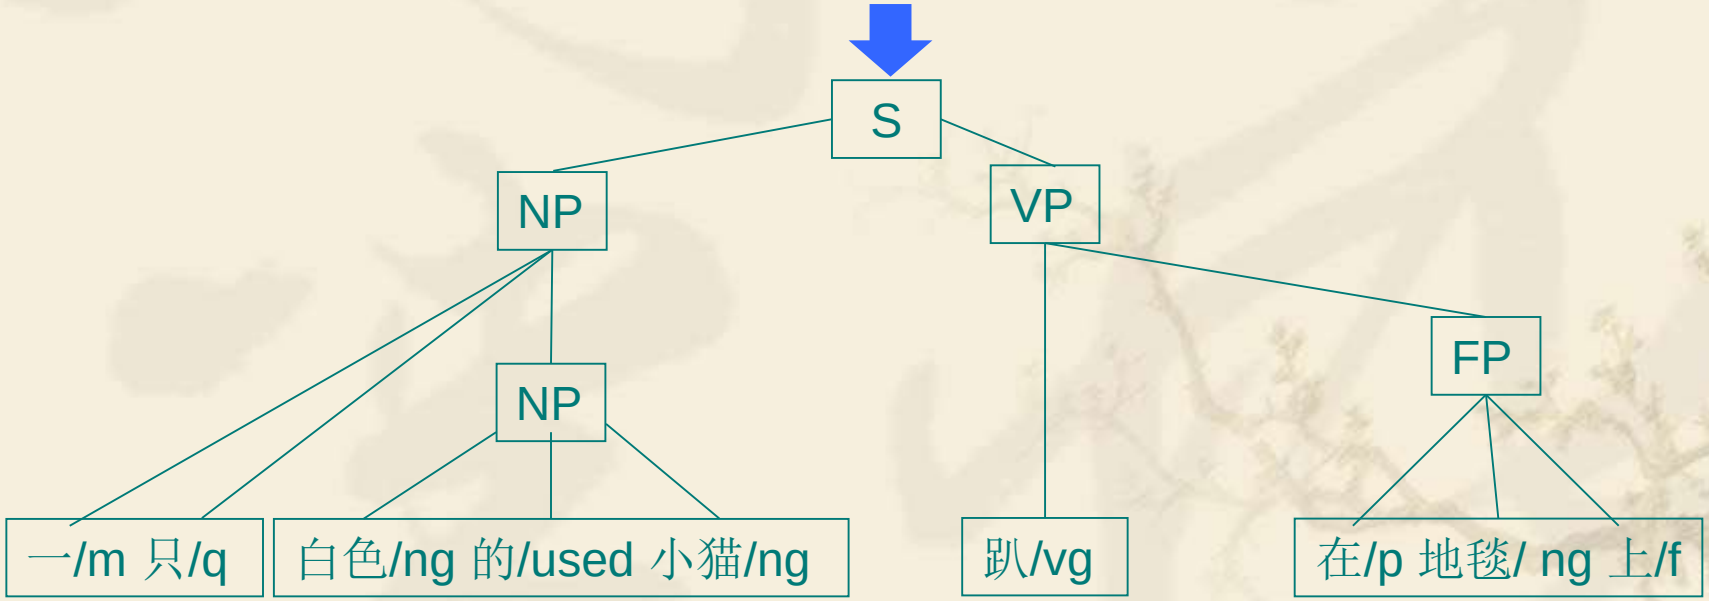

1.概述

- 形式化的句法树不足以描述自然语言

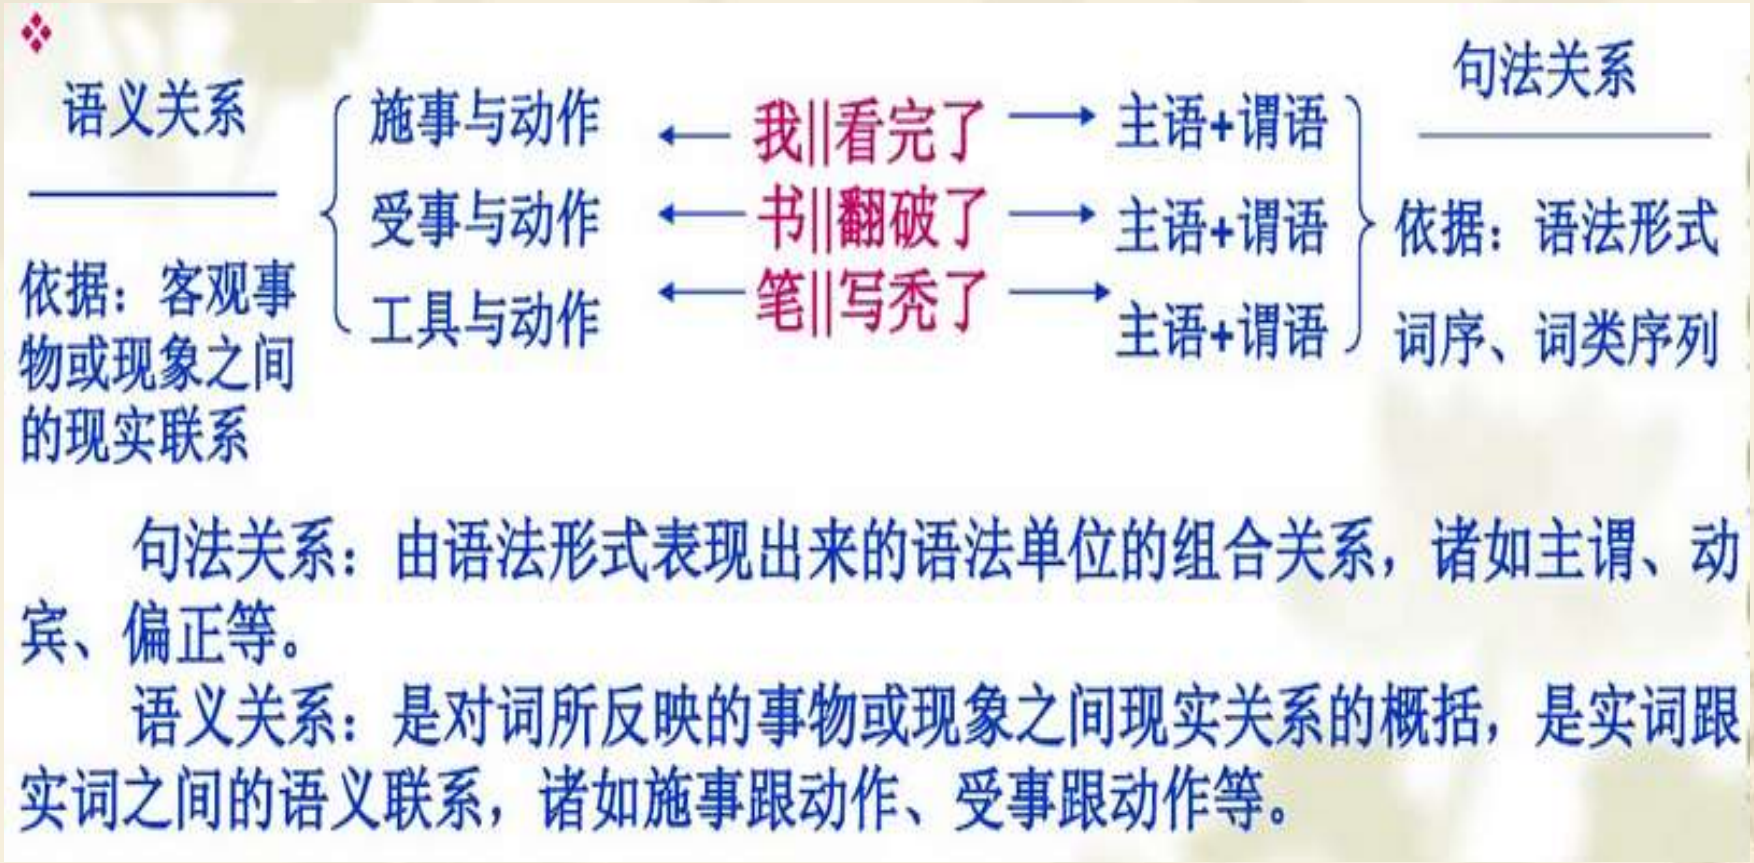

句法关系：由语法形式表现出来的语法单位的组合关系，诸如主谓、动宾、偏正等。

语义关系：是对词所反映的事物或现象之间现实关系的概括，是实词跟实词之间的语义联系，诸如施事跟动作、受事跟动作等。

1.概述

- 句法和语义的另一种区别
  - 他 跑 马拉松 vs 他 跑 出租
  - 北方人 吃 面 vs 他 吃 食堂
  - 他 喝 咖啡 vs 他 喝 酒吧？
  - 极端情况：句法正确，但不可理解！

    一 只 粉色的 大象 飞 在 小河 里
- 句法 -> 语义

1.概述

◆**语义计算的任务**：解释自然语言句子或篇章各部分(词、词组、句子、段落、篇章)的意义。

◆**面临的困难**：

- 自然语言句子中存在大量的歧义，涉及指代、同义/多义、量词的辖域、隐喻等；
- 同一句子对于不同的人来说可能有不同的理解；
- 语义计算的理论、方法、模型尚不成熟。

1.概述

- 语义是一个比较复杂的概念
  - 符号学：词的指称(signified) | 外，客体、静态
  - 心理图像：image | 内，主体、静态
  - 说话者的意图：speech act | 内，个体、动态
  - 情景语义： | 外，时空、动态
- 语义计算的经典框架
  - 格语法(Fillmore,1966)：施事、受事、工具….
  - 语义网络(Quilian, 1968)：is-a, part-of, is
  - 概念依存(Schank, 1970s)：动作基元、剧本、计划

1.概述

- 词义是语义计算的一个基础
- 词义歧义及词义处理是一个关键环节
- 本节重点讨论词义消歧

2. 词汇语义及其表示

- 义项：词典中的表示，语义学中或称“义位”
  - 义位：语义系统中能独立存在的基本语义单位
- “编辑”一词在词典中：
  - ①对资料或现成的作品进行整理、加工
  - ②做编辑工作的人 更多
- 容易发现：同义词、近义词、反义词
- 进一步区分出：上下位、整体部分关系

2. 词汇语义及其表示

- 上下义关系
  - 指两个义位(上义义位和下义义位)间存在类属关系

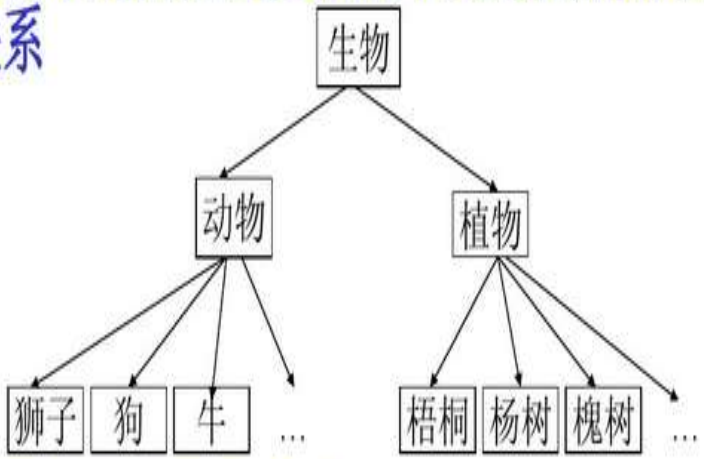

  - 狮子和狗是同位关系(co-hyponyms)
  - 杨树是植物的下位关系词(hyponym)
  - 生物是动物和植物的上义词(hypernymy)

(2) 整体-部分关系 part-meronym

- 一个义位所表达的对象是另一个义位所表达的对象的组成部分。
  - 例如：手是身体的一部分；
  - body, arm
  - house, roof

知识图谱需要攻克这些问题

https://wenku.baidu.com/view/faeefc23647d27284b73516b.html

2. 词汇语义及其表示

- 语义场：Semantic field
  - 义素：是构成义位的最小意义单位（Bloomfield）
  - 一个语言的所有义位集合是该语言的最大语义场
  - 分类表示 vs 义素分解

	亲属	同胞	年长	男性
哥哥	+	+	+	+
姐姐	+	+	+	-
弟弟	+	+	-	+
妹妹	+	+	-	-

3.多义词

- 多义词是自然语言中普遍存在的现象
  - 衣食所安　死于安乐　安求其能千里也
  - 出则无敌国外患者　水落而石出　不复出焉
  - bank table title book fly
- 在NLP的许多应用领域，都需要识别出多义词在具体语境中的意思。

3.多义词

- **语义歧义**：很多词语具有几个意思或语义，如果将这样的词从上下文中独立出来，就会产生语义歧义
  - 衣服单薄　　人手单薄
  - 生意很清淡　口味比较清淡
  - 基本工很厚实　家底很厚实
  - 我就来　我就不来，我就记得一句话

3. 多义词

- 常用词（字）的多义情况

Marrian-Webster袖珍词典		《现代汉语通用字典》	
词形	义项数	词形	义项数
go	63	打	26
fall	35	上	20
run	35	下	19
turn	31	干	19
way	31	子	18
work	31	着	18
do	30	生	18
draw	30	和	18
play	29	点	18
get	26	折	17

引自童翔1993，《汉语真实文本的语义自动标注》

3. 多义词

- 同义词词林
- 《同义词词林》，梅家驹等，1983，上海辞书出版社

	单字词		多字词		
	词条数	百分比	词条数	百分比	
单义词	1973	52.3%	40751	87.9%	42724
多义词	1801	47.7%	5629	12.1%	7430(14.8%)
总计	3774	100%	46380	100%	50154

- 引自黄昌宁等《词义排歧的一种语言模型》，载《语言文字应用》2000年第3期

3. 多义词

- 人对多义词的理解
  - You shall know a word by the company it keeps.

    ----J. R. Firth, 1957

4. 词义消歧WSD (word sense disambiguation)

- 多义词的计算

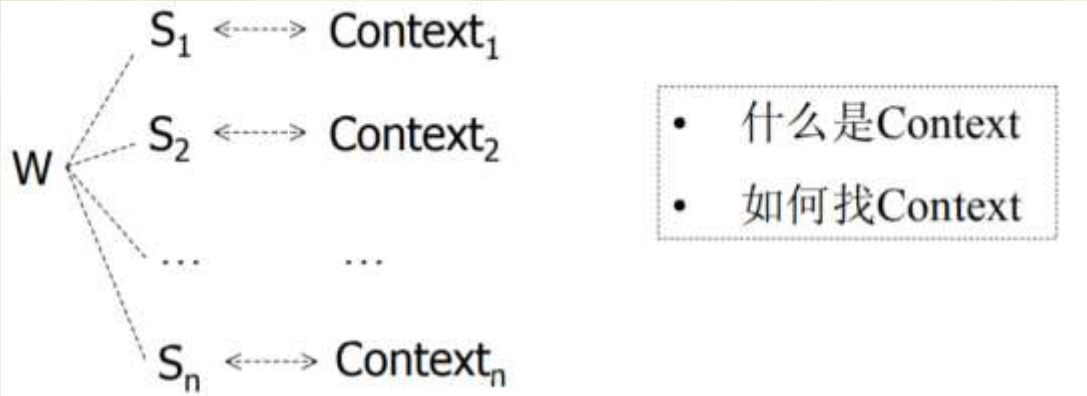

- 如何确定具体语境中多义词的确切意义？-词义标注 / 消歧
- 如何针对对一类多义词的判别：寻找具有区别意义C1,C2,...,Cn
- 对Ci的认识不同，寻找Ci的途径也不同->不同的WSD方法

4. 词义消歧

- 词义消歧任务与处理环节
  - 词义标注/消歧：确定一个多义词在具体语境中的义项
  - WSD需要解决三个问题：

(1)如何判断一个词是不是多义词？

如何表示一个多义词的不同意思？

(2)对每个多义词，预先要有关于它的

各个不同义项的清晰的区分标准

} WSD所需的基础资源

(3)对出现在具体语境中的每个多义词，为它确定一个合适的义项

4.词义消歧（WSD）

- 不同的WSD系统在实现两步骤的具体策略不同：

基于机器词典的WSD
基于义类词典的WSD
基于语料库的WSD
基于统计方法的WSD
基于规则的WSD
……

由名字可知WSD使用哪种资源，采用什么策略进行词义排歧

4.1词义消歧—基于知识库的方法

- 基于词典释义的WSD
  - 词典是语言学家对词语知识归纳总结的结果
  - 词典中对多义词的各个义项的描写是对多义词的不同使用情况的总结

从 cóng 325

craft

【从实】 cóngshí 按真实情况;如实 in the light of the fact (that ...); based on the fact;～回答 answer honestly (frankly)

【从事】 cóngshì ❶ 投身到(事业中去) pursue; go in for; devote oneself to; throw oneself into; work on; occupy oneself with; take part in; go about; take up; be engaged in; be bound up in;～革命 devote oneself to revolutionary work |～文艺创作 engage in literary and artistic creation ❷ (按某种办法)处理 (in certain way) deal with;军法～ deal with according to military law; court-martial sb.

【从属】 cóngshǔ 依从;附属 subordinate; dependent;～关系 relationship of subordination; affiliation

【从俗】 cóngsú ❶ 按照风俗习惯;遵循通常做法 follow local custom; follow tradition; conform to convention;～办理 proceed according to local customs |～节俭 conform to conventions while adhering to the principle of simplicity ❷ 指顺从时俗 follow what the majority are doing;～浮沉 experience ups and downs like most people do; live an ordinary life without much of a struggle to better one's situation

【从速】 cóngsù 赶快;赶紧 as soon as possible; without delay;～处理 deal with the matter as soon as possible; settle the matter quickly | 存货不多,欲购～。 Buy now, while they last.

【从头】 cóngtóu (～儿 cóngtóur) ❶ 从最初(做) from the beginning; from scratch;～干起 start from the very beginning ❷ 重新(做) afresh; anew; once again;～再来 start afresh; start all over again

【从先】 cóngxiān (方 *dial.*) same as 从前 cóngqián;他身体比～结实多了。 He's much stronger than before.

4.1词义消歧—基于知识库的方法

- 基于词典释义的WSD方法
  - 利用词典中的释义文本进行WSD

    Lesk，1986，准确率50%-70%之间
  - E.g. 词典释义：cone
    - a mess of ovule-bearing or pollen-bearing scales or bracts in trees of the pine family or in cycads that are arranged usually on a somewhat elongated axis. 松果
    - something that resembles a cone in shape: as ...a crisp cone-shaped wafer for hoding ice cream. 蛋卷冰淇淋
  - 语境消歧：
    - 上下文中出现了tree → 第1个义项
    - 上下文中出现了ice → 第2个义项

4.1词义消歧—基于知识库的方法

❖ 基于词典释义的WSD方法

- 已知：

1)一个多义词W有若干义项($S_1, S_2, \ldots, S_m$)；

2)多义词W的每个义项(S_i)在词典中分别有一个释义(D_i)，每个释义(D_i)实际上代表了一组出现在该释义中的词{$a_1, a_2, a_3, \ldots$}；

3)多义词W在一个具体的上下文(C)中出现时，前后有一些词($W_1, W_2, \ldots$)，这些词将作为判定多义词W意思的上下文特征词；

4)每个特征词(W_j)在词典中也分别有释义($E_1, E_2, \ldots$)，每个释义(E_{wj})实际代表了一组出现在该释义中的词{$b_1, b_2, b_3, \ldots$}。

- 判断多义词在语境中的义项：对每个义项S_i计算 $\mathrm{Score}(S_i) = D_i \cap (\bigcup_{w_j \in C} E_{w_j})$

即 $\{a_1, a_2, a_3, \ldots\} \cap (\{b_1, b_2, \ldots\} \cup \ldots \{b_1', \ldots, b_k'\})$

取最大值所对应的S_i，即为该多义词的义项。

4.1词义消歧—基于知识库的方法

- 基于词典释义的WSD方法
  - 上述算法的具体过程描述

```
1 comment: Given: context c
2 for all senses s_k of w do
3       score(s_k) = overlap(D_k, ⋃_{v_j in c} E_{v_j})
4 end
5 choose s' s.t. s' = arg max_{s_k} score(s_k)
```

Lesk 的基于词典的消歧算法。D_k 是语义 s_k 的词典定义。E_{v_j} 是词 v_j 的词典定义中出现的词集（换句话说，就是所有 v_j 语义定义的联合）

4.1词义消歧—基于知识库的方法

- 基于词典释义的WSD方法

Word	Sense	Definition(from Collins COBUILD)
pen	S1:笔	A pen is a long thin object which you use to write in ink.
	S2:围栏	A pen is a small area with a fense round it in which farm animals are kept for a short time.
sheep	S1:羊	A sheep is a farm animal with a thick wolly coat.
	...	...

- 多义词pen：The **sheep** has been penned for three days.
- 在pen的上下文中只有sheep这个词释义和pen的一个释义有交集词

Score(S1) = 0

Score(S2) = 2

} 取S2

4.1词义消歧—基于知识库的方法

- 基于词典释义的WSD方法
- 总结：
  - 用词典资源进行词义排歧，是利用词典中对多义词的各个义项的描写，求多义词的释义跟其上下文环境词的释义之间的交集，判断词义的亲和程度，来确定词义；
  - 由于词典释义的概括性，这种方法应用于实际语料中多义词的排歧，效果不一定理想。

4.1词义消歧—基于知识库的方法

❖ 基于义类词典的WSD方法

- Yarowsky, 1992. 试验12个多义词，准确率92%
- 基本思想：一个多义词在义类词典中可能分属不同的义类，在具体语境中，确定了一个多义词的义类实际上就刻画了它的一个义项。
  - 如：“crane”有两个意思，一是指“吊车”，一是指“鹤”。前者属于“工具/机械”这个义类；后者属于“动物”这个义类。如果能够确定“crane”出现在具体语境中时属于哪个义类，实际上也就知道了“crane”的义项。

4.1词义消歧—基于知识库的方法

- 基于义类词典的WSD方法
  - 需要解决的两个问题：

    1.表示每一个义类的特征词，以及每个特征词对于该义类的权重；

    2.对于一个具体语境中的多义词，根据其周围词隶属于某个义类的可能性大小，选择其中可能性最大的那个义类作为该多义词对应的义项标记。

4.1词义消歧—基于知识库的方法

❖ 基于义类词典的WSD方法

基于义类词典的WSD的过程（第一步）：

- 对Roget词典中每个义类（共1041个类）中所有的词，收集包含这些词的上下文C（每个词的上下文长度为前后100个词）作为训练数据
- Yarowsky收集的训练语料来自Grolier百科全书1991年的电子版，1000万词规模。 如包含“工具/仪器”类中部分词的语料：

Training Data (Words in Context)
... CARVING .SB The gutter **adz** has a concave blade for form ...
... uipment such as a hydraulic **shovel** capable of lifting 26 cubic ...
... on .SB Resembling a power **shovel** mounted on a floating bul ...
... uipment , valves for nuclear **generators** , oil-refinery turbines ...
... 00 BC , flint-edged wooden **sickles** were used to gather wild ...
... l-penetrating carbide-tipped **drills** forced manufacturers to fi ...
... ent heightens the colors .SB **Drills** live in the forests of equa ...
... traditional ABC method and **drill** were unchanged , and dissa ...
... nter of rotation .PP A tower **crane** is an assembly of fabricat ...
... rshy areas .SB The crowned **crane** , however , occasionally ...

4.1词义消歧—基于知识库的方法

❖ 基于义类词典的WSD方法

基于义类词典的WSD的过程（第二步）

- 对C进行统计，找出能够有效地标示每个义类的特征词，并计算各个特征词的权值：

$$Weight(w) = \log(\frac{P(w \mid RCat)}{P(w)})$$

P(w|Rcat)表示w出现在Rcat类中的概率，P(w)表示w出现在训练语料库中的总概率

- 如：

“动物”类特征词	“工具”类特征词
species(2.3), family(1.7), bird(2.6), fish(2.4), breed(2.2), animal(1.7), tail(2.7), …	tool(3.7), machine(2.7), engine(2.6), blade(3.8), cut(2.6), saw(5.1), lever(4.1),…

4.1词义消歧—基于知识库的方法

❖ 基于义类词典的WSD方法

基于义类词典的WSD的过程（第三步）

- 判断在某个具体的语境中出现的多义词所属的义类：
  - 如果在该多义词的上下文中能够且只能找到一个义类的特征词，则该多义词即属于这个义类；
  - 如果在该多义词的上下文中找到若干个特征词，且分别对应着不同的义类，根据Bayes法则，分别求这些特征词所对应的不同义类的权值之和，哪个义类的特征词权值之和最大，该多义词就属于哪个义类。

4.1词义消歧—基于知识库的方法

- 基于义类词典的WSD方法

…lift water and to grind grain .PP Treadmills attached to cranes were used to lift heavy objects from Roman times , …

TOOLS/MACHINE	Weight	ANIMAL/INSECT	Weight
lift	2.44	water	0.76
lift	2.44		
grain	1.68		
used	1.32		
heavy	1.28		
Treadmills	1.16		
attached	0.58		
grind	0.29		
water	0.11		
TOTAL	11.30	TOTAL	0.76

4.1词义消歧—基于知识库的方法

- 基于义类词典的WSD方法
  - 上述过程描述：

```
1  comment: Categorize contexts based on categorization of words
2  for all contexts c_i in the corpus do
3      for all thesaurus categories t_l do
4          score(c_i, t_l) = log P(c_i|t_l)/P(c_i) P(t_l)
5      end
6  end
7  t(c_i) = {t_l | score(c_i, t_l) > α}
8  comment: Categorize words based on categorization of contexts
9  for all words v_j in the vocabulary do
10     V_j = {c | v_j in c}
11 end
12 for all topics t_l do
13     T_l = {c | t_l ∈ t(c)}
14 end
15 for all words v_j, all topics t_l do
16     P(v_j|t_l) = |V_j ∩ T_l| / Σ_j |V_j ∩ T_l|
17 end
18 for all topics t_l do
19     P(t_l) = (Σ_j |V_j ∩ T_l|) / (Σ_l Σ_j |V_j ∩ T_l|)
20 end
21 comment: Disambiguation
22 for all senses s_k of w occurring in c do
23     score(s_k) = log P(t(s_k)) + Σ_{v_j in c} log P(v_j|t(s_k))
24 end
25 choose s' s.t. s' = arg max_{s_k} score(s_k)
```

调整的基于类义辞典消歧的 Yarowsky 算法。该算法基于类义辞典消歧并调整词汇的语义类。第16行中的$P(v_j \mid t_l)$是含有词v_j的topic t_l的上下文所占比例的估计

4.1词义消歧—基于知识库的方法

- 基于义类词典的WSD方法

基于词典消歧的一些结果。这个表显示了三个歧义词的语义，它们相应的Roget范畴和图7.5中算法的准确率。改编自（Yarowsky 1992）

单词	语义	Roget范畴	准确率
bass	musical senses	MUSIC	99%
	fish	ANIMAL, INSECT	100%
star	space object	UNIVERSE	96%
	celebrity	ENTERTAINER	95%
	star shaped object	INSIGNIA	82%
interest	curiosity	REASONING	88%
	advantage	INJUSTICE	34%
	financial	DEBT	90%
	share	PROPERTY	38%

4.1词义消歧—基于知识库的方法

❖ 基于义类词典的WSD方法

总结：

- 可以理解为是对一个多义词所处语境的“主题领域”的猜测，假定如果当前主题领域猜对了，该多义词的义项也能判定正确；
- 对训练语料库不需要事先标注；
- 对义项区别依赖大语境的多义词效果较好（如名词）；
- 对义项区别对应着义类区别的多义词效果较好；
- 对那些不依靠大语境提示词义的多义词效果较差（如动词和形容词）；
- 对义项区别不依赖主题的多义词效果较差。

——随着电子义类词典资源的丰富（如Wordnet），Thesaurus-based WSD 可以在更多资源基础上应用，效果会有一定程度的提高。

4.2 词义消歧——基于统计的方法

❖ 基于互信息的WSD方法

- 基于互信息的WSD方法：Brown, et al, 1991
- 思路：要判断多义词在具体语境下的意义，关键是找到能够指示该多义词意义的示意特征（indicator）

多义词（法语）	译词（英语）	示意特征	示意特征的具体取值
Prendre [prã:dr]	take	当前词的宾语	当prendre的宾语是mesure时
	make	当前词的宾语	当prendre的宾语是décision时
vouloir [vulwa:r]	want	当前词的时态	当vouloir为现在时形式时
	like	当前词的时态	当vouloir为条件时态形式时
cent [sã]	percent	当前词的左边一个词	当cent左边词语为per时
	c.	当前词的左边一个词	当cent左边是数字时

关于互信息的概念

- 互信息：I（X；Y）反映的是在知道了Y的值以后X的不确定性的减少量。
- 可理解为Y的值透露了多少关于X的信息量。
- 互信息的定义：

$$I(X;Y)=\sum_{x\epsilon X}\sum_{y\epsilon Y}p(x,y)\,log\frac{p(x,y)}{p(x)\,p(y)}$$

- 请课下阅读：统计自然语言处理 宗成庆 S2.2

4.2 词义消歧——基于统计的方法

❖ 基于互信息的WSD方法

如何得到多义词的示意特征？其取值是什么？— Flip-Flop算法

- 假设：
  - 一个法语多义词在英语中存在若干译词$t_1,t_2,\ldots,t_m$
  - 对于一个多义词，其示意特征可能的取值为$v_1,v_2,\ldots,v_n$

$$I(R;Q) = \sum_{x\in R}\sum_{y\in Q} p(x,y)log\frac{p(x,y)}{p(x)p(y)}$$

（1）随机地将$t_1,t_2,\ldots,t_m$分为两类，可记作$R=\{r_1, r_2\}$；

（2）寻找$v_1,v_2,\ldots,v_n$的一个分类$Q=\{q_1,q_2\}$，使得Q与R的互信息值I(R,Q)最大。根据Q，再调整R的分类，反复进行这个过程，直到I(R,Q)的值不能再提高（或变化甚微）为止。

4.2 词义消歧——基于统计的方法

- 基于互信息的WSD方法

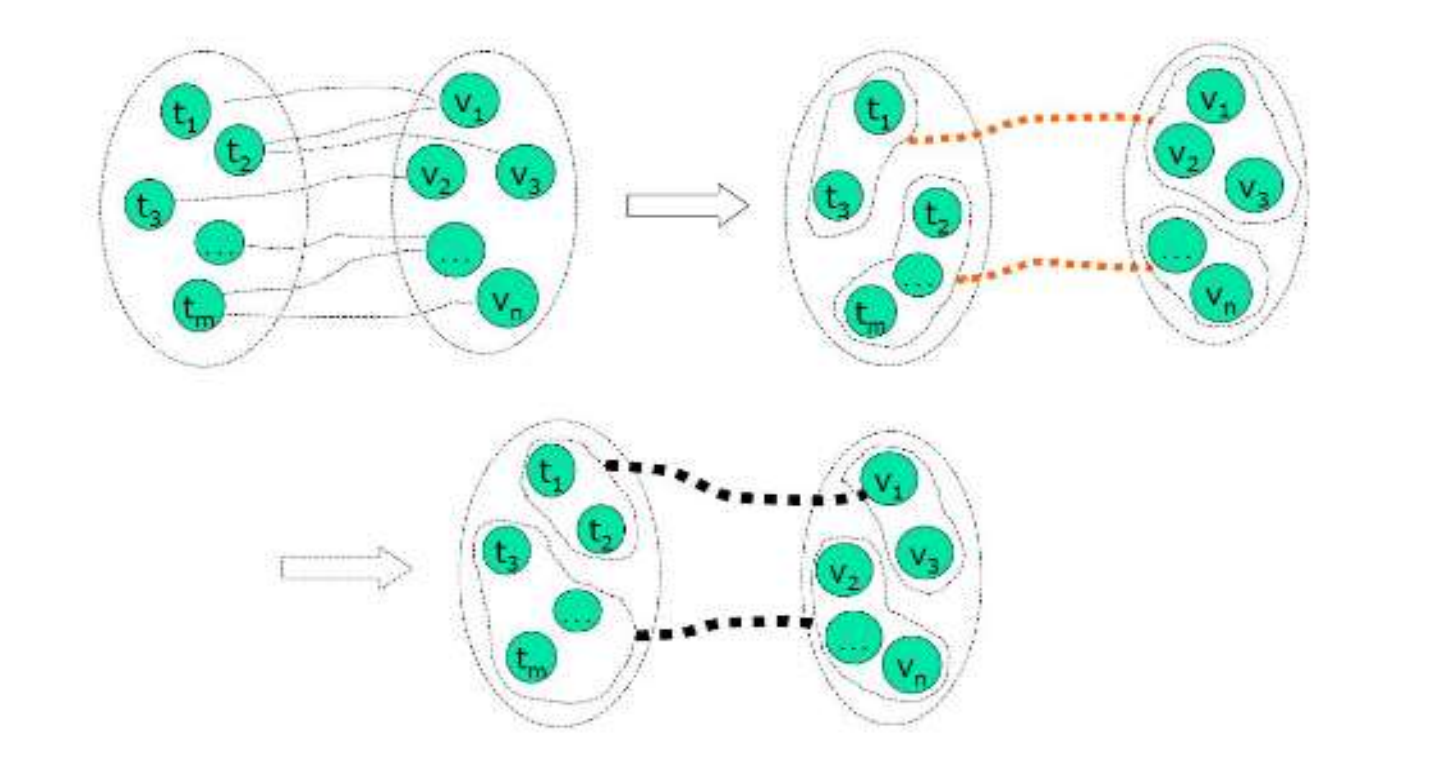

4.2 词义消歧——基于统计的方法

- 基于互信息的WSD方法

示例：

- 看：{t1=读, t2=观看}
- {v1=电影,v2=报,v3=书,v4=小说,v5=电视}

- Count(t1)=3, Count(t2)=2,
  Count(v1)…=Count(v5)=1
  Count(t1,v1)=Count(t1,v5)=0,
  Count(t1,v2)=Count(t1,v3)=Count(t1,v4)=1
  Count(t2,v1)=Count(t2,v5)=1
  Count(t2,v2)=Count(t2,v3)=Count(t2,v4)=0

带有语义标记的训练语料库

看电影（观看）
看报（读）
看书（读）
看小说（读）
看电视（观看）
……

样本容量N=10

4.2 词义消歧——基于统计的方法

- 基于互信息的WSD方法

r1:{t1=读}　r2:{t2=观看}

分类1：q1 {v1=电影,v2=报}　q2 {v3=书,v4=小说,v5=电视}

$$I_1(R,Q)= p(t_1,q_1)\log\frac{p(t_1,q_1)}{p(t_1)p(q_1)}+\ldots+p(t_2,q_2)\log\frac{p(t_2,q_2)}{p(t_2)p(q_2)}$$

$$= \frac{1}{10}\log\frac{10\times1}{3\times2}+\frac{2}{10}\log\frac{10\times2}{3\times3}+\frac{1}{10}\log\frac{10\times1}{2\times2}+\frac{1}{10}\log\frac{10\times1}{2\times3}$$

$$= \frac{5}{10}\log10-\frac{1}{10}\log2430$$

$I_2(R,Q)> I_1(R,Q)$

分类2：q1 {v2=报,v3=书,v4=小说}　q2 {v1=电影,v5=电视}

$$I_2(R,Q)= \frac{3}{10}\log\frac{10\times3}{3\times3}+\frac{0}{10}\log\frac{10\times0}{3\times2}+\frac{0}{10}\log\frac{10\times0}{2\times3}+\frac{2}{10}\log\frac{10\times2}{2\times2}$$

$$= \frac{5}{10}\log10-\frac{1}{10}\log108$$

4.2 词义消歧——基于统计的方法

- 基于互信息的WSD方法

多义词的示意特征以及特征值都确定下来后，判定多义词的义项：

1. 扫描该多义词所在的上下文环境，取得该多义词示意特征的当前值V_i；
2. 如果V_i属于q_1，则多义词义项为r_1；如果V_i属于q_2，则多义词义项为r_2。

4.2 词义消歧——基于统计的方法

❖ 基于Bayes判别的WSD方法

- 基于Bayes判别的WSD方法：

  Gale et al., 1992，试验了6个多义词，准确率90%

- 基本思想：

  计算多义词W出现在给定上下文语境C（包括多个词$w_1,w_2,\ldots,w_n$）中，标注为各个义项S_i概率大小$P(s_i|C)$，使$P(s_i|C)$最大的义项即为该多义词W的义项标注。

4.2 词义消歧——基于统计的方法

- 基于Bayes判别的WSD方法

  - 多义词w 有多个义项 $s_1, s_2, \ldots, s_i, \ldots$
  - 上下位语境C = $w_1, w_2, \ldots, w_n$

  → $$P(s_i \mid C) = \frac{P(C \mid s_i)P(s_i)}{P(C)}$$

  $$s' = \arg\max_{s_i} P(s_i \mid C) = \arg\max_{s_i} \frac{P(C \mid s_i)P(s_i)}{P(C)}$$

  $$= \arg\max_{s_i} P(C \mid s_i)P(s_i)$$

  $$P(s_i) = \frac{Count(s_i)}{Count(w)}$$

  $$P(C \mid s_i) = P(\{w_j \mid w_j \in C\} \mid s_i) = \prod_{w_j \in C} \frac{Count(w_j, s_i)}{Count(s_i)}$$

4.2 词义消歧——基于统计的方法

- 基于Bayes判别的WSD方法

词义排歧算法（Disambiguation）：

```
for all sense s_i of w        do
        score(s_i) = logP(s_i)
        for all words w_j in the context of w  do
                score(s_i)=score(s_i) + logP(w_j|s_i)
        end
end
choose s' = argmax score(s_i)
```

4.2 词义消歧——基于统计的方法

- 基于Bayes判别的WSD方法

- 例：词义知识库示例

w_j / s_i	$P(s_i)$	…	书	武侠	电影	股市	行情	桌子	小说	…
看$_1$	0.3	…	0.40	0.10	0.01	0.01	0	0.20	0.27	…
看$_2$	0.5	…	0	0.25	0.5	0.01	0	0	0.15	…
看$_3$	0.2	…	0.01	0.03	0.05	0.45	0.45	0	0	…
…	…	…	…	…	…	…	…	…	…	…

4.2 词义消歧——基于统计的方法

- 我看过由同名武侠小说改编的电影

$score(看_1) = log0.3 + log0.1 + log0.27 + log0.01$

$score(看_2) = log0.5 + log0.25 + log0.15 + log0.5$

$score(看_3) = log0.2 + log0.03 + log0.05$

→ $score(看_2)$最大，所以当前语境下是“看”的第2个义项

4.2 词义消歧——基于统计的方法

- 基于Bayes判别的WSD方法

总结：

(1) 标注好词义的语料库（training corpus）；

(2) 从标注语料库训练“语境”与词义之间的依赖关系，得到“词义知识库”；

(3) 对于一个输入句子中的多义词，根据“词义知识库”中的知识，计算它在当前“语境”下，取哪一个义项的可能性最高，就将该义项判定为这个多义词在当前语境下的意思。

4.3 词义消歧——基于多分类器集成

- 多个消歧性能优良的系统都是基于多分类集成学习方法
- 词义消歧是一个较为经典的分类问题
- 曾用于词义消歧的分类器：
  - 决策树、决策表、朴素贝叶斯、最大熵、支持向量机...
- 集成学习方法的有效条件：
  - 每个单分类器的错误率低于0.5
  - 单分类器之间各不相同形成互补

4.3 词义消歧——基于多分类器集成

- 单分类器的选择

1. 支持向量机(SVM)

基本原理：寻找一个最优超平面使两个类别之间的间隔最大。

定义二值分类样本$(x_1, y_1),\ldots,(x_n, y_n)$

$$(x_i \in R^n, y_i \in \{+1, -1\})$$

决策函数

$$g(x) = sign[\sum_{i=1}^{n} a_i y_i K(x_i, x) + b]$$

核心函数 $K(x_i, x)$

4.3 词义消歧——基于多分类器集成

- 单分类器的选择

2. 朴素贝叶斯(NB)

$$P(S_i|C) = \frac{P(C|S_i)P(S_i)}{P(C)}$$

3. 决策树(DT)

决策树是一种不稳定的学习算法，不同的剪枝策略和不同的实验设置会使实验结果发生较大波动。

$C = 0.5$时消歧准确率较高

4.3 词义消歧——基于多分类器集成

- 三种分类器结果对比

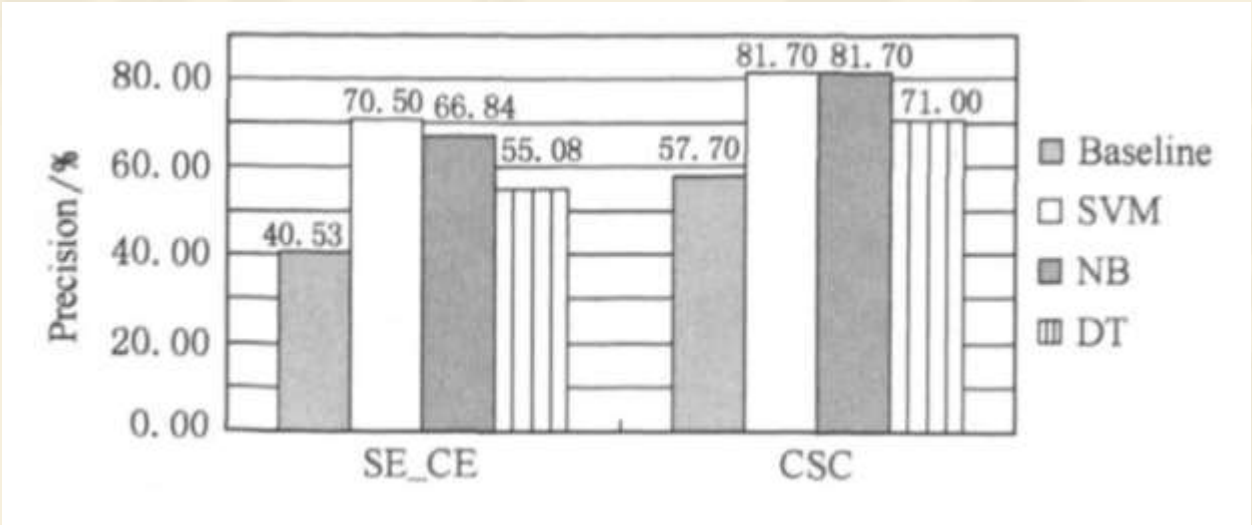

CSC：北京大学现代汉语语义标注语料

SE_CE：国际语义评测SemEval-2007的中英文对译选择词消歧任务的数据

Baseline：最大频率词义

4.3 词义消歧——基于多分类器集成

- 多分类器集成方法

1. 基于概率的方法

设词语w有m个语义$(w_1,\ldots,w_j,\ldots,w_m)$,存在$R$个不同的分类器$f_i(i=1,\ldots,R)$,$P(w_j|f_i)$表示分类器对词义类别的输出概率,$P(w_j)$表示词义类别的先验概率,$w$应当赋予的词义类别是:

$$\hat{w}=\underset{j}{argmax}\ P(w_j|f_1,\ldots,f_R)$$

假设各分类器彼此条件独立，根据贝叶斯公式推导可得

4.3 词义消歧——基于多分类器集成

- 多分类器集成方法

1. 基于概率的方法

得到：

最大值(Max)

$$\hat{w} = \underset{j}{argmax}\left[\max_{i=1}^{R} P(w_j|f_i)\right]$$

最小值(Min)

$$\hat{w} = \underset{j}{argmax}\left[\min_{i=1}^{R} P(w_j|f_i)\right]$$

均值(Av)

$$\hat{w} = \underset{j}{argmax}\left[\frac{1}{R}\sum_{i=1}^{R} P(w_j|f_i)\right]$$

4.3 词义消歧——基于多分类器集成

- 多分类器集成方法

2. 基于投票的集成方法

最大投票(majority voting, MV)

将输出概率$P(w_j|f_i)$映射成是与否的二值函数：

$$\Delta_{ji}=\begin{cases}1, \text{ if } P(w_j|f_i)=\max\limits_k P(w_k|f_i),\\ 0, \text{ otherwise,}\end{cases}$$

$$\hat{w}=\arg\max_j \sum_i \Delta_{ji}$$

序列投票(rank-based voting, RBV)

每个分类器的投票值与输出概率由小到大的序列成反比：

$$\Delta_{ji}=\frac{1}{rank_i}, \qquad \hat{w}=\arg\max_j \sum_i \Delta_{ji}$$

4.3 词义消歧——基于多分类器集成

- 多分类器集成方法

3. 基于性能的集成方法

加权投票(weighted voting, WV)与最大投票的区别在于要考虑分类器的权重$P(f_i)$

$$\Delta_{ji}=\begin{cases}1, \text{ if } P(w_j|f_i)=\max\limits_{k} P(w_k|f_i),\\ 0, \text{ otherwise,}\end{cases}$$

$$\hat{w}=\arg\max_{j}\sum_{i}(\Delta_{ji}\times P(f_i))$$

概率加权(weighted probability, WP)，与加权投票不同的是对输出概率进行加权集成

$$\hat{w}=\arg\max_{j=1}^{m}\sum_{i=1}^{n}(P(w_j|f_i)\times P(f_i))$$

4.3 词义消歧——基于多分类器集成

- 多分类器集成方法在SE_CE上的实验结果(左)
- 在CSC上的实验结果(右)

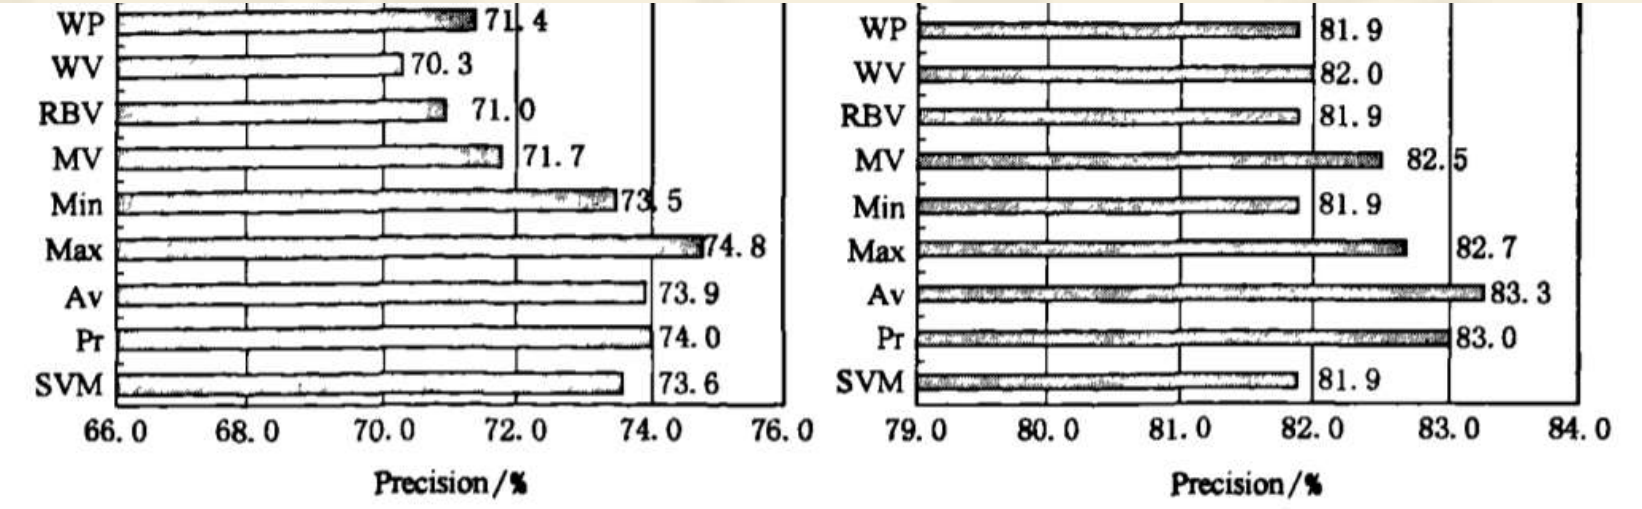

- 消歧性能突出的依次是平均值Av，乘法规则Pr和最大值Max

4.3 词义消歧——基于多分类器集成

- 总结
  - 还有很多问题需要探讨
    - 如何选用更有效的分类器
    - 单分类器的结果怎样更高效地集成
    - 如何在单分类器中选取更有效的特征
  - 集成学习的研究对自然语言处理中的其他任务(文本分类、情感分析等)具有方法论的启示意义

WSD小结

- 各种WSD技术和方法解决两个问题：
  - 如何确定用于词义排歧的可靠知识？
    - 语境中的某个特定的提示特征？大语境？普通语文词典？义类词典？带语义标记的语料库？
  - 如何低代价，高效地，大规模地获得这样的知识？
    - 人工？统计—机器自动获取？

WSD小结

- WSD研究的困难
  - 词义缺乏明确清晰的定义
  - 搭配并不能完全确定一个词的意义
    - “有的是钱” —— “有的是医生”
  - 词义是相互依赖的
    - 豆腐放坏了 豆腐放早了(not in context)
    - 打酱油 打翻了酱油
    - 打眼睛 打湿了她的眼睛
  - 对WSD系统的评价困难

WSD小结

- 另一个思路
  - 将词义歧义在任务整体模型中解决；
  - 需要更直接更明确的语义表示；
  - 需要任务整体模型具备更强大消歧能力；